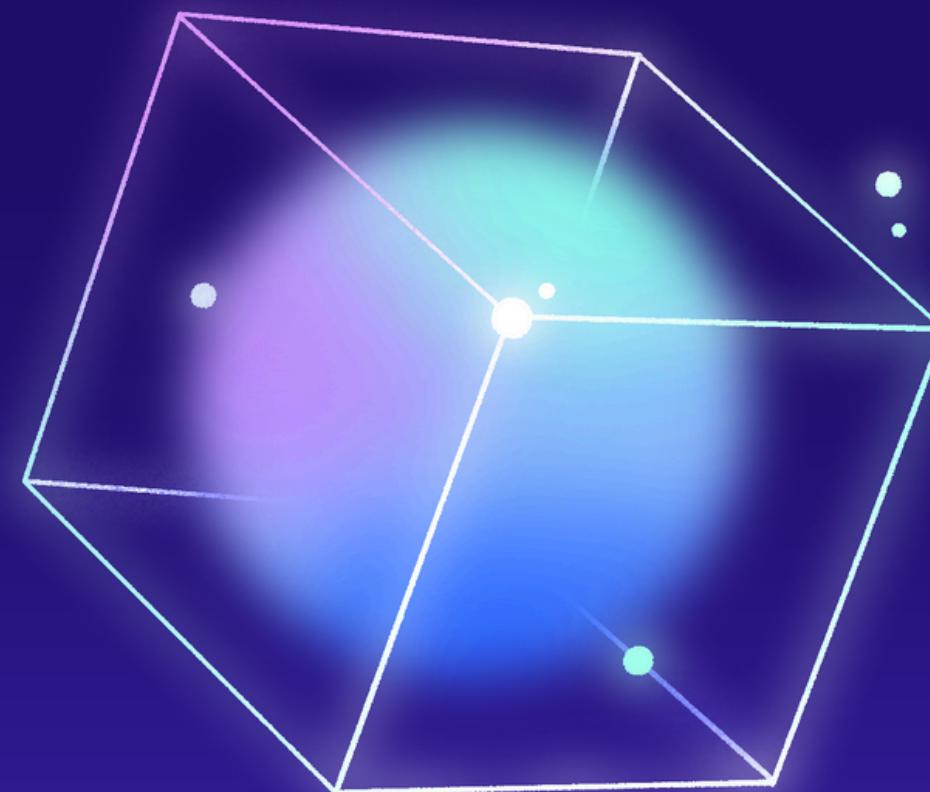




# GELİŞMİŞ DENİZ GÖZLEMİ: SAR TABANLI GEMİ TESPİTİ İÇİN CNN ALGORİTMALARININ KULLANIMI

...

# ÖZET



Bu çalışma, deniz gözetiminde gemi tespiti için Sentinel-1 SAR uyduları ve Faster R-CNN algoritmasını kullanarak %86.11 doğruluk oranı elde etmiştir. Faster R-CNN, görüntülerdeki nesneleri algılamada yüksek performans gösteren derin öğrenme tabanlı bir nesne algılama yöntemidir. Sentinel-1, Avrupa Uzay Ajansı tarafından işletilen ve yüksek mekansal çözünürlüklü radar görüntüleri sağlayan bir uydudur. Çalışma, Sentinel-1 verileri ile Faster R-CNN'nin kombinasyonunun etkinliğini kanıtlamış ve deniz trafiği yönetimi, güvenlik ve taşımacılık uygulamaları için önemli katkılar sunabileceğini göstermiştir.

• • •

# GİRİŞ

Gemi tespiti, deniz güvenliği, gemi trafiği yönetimi, çevresel izleme ve arama kurtarma operasyonları gibi birçok kritik alanda önemli bir araştırma konusudur. Uydu ve radar görüntüleme teknolojilerindeki gelişmelerle birlikte, Sentinel-1 SAR (Sentetik Açıklıklı Radar) verileri kullanılarak gemi tespitinde önemli ilerlemeler kaydedilmiştir. Bu çalışmada, Faster R-CNN (Region-Based Convolutional Neural Network) algoritması kullanılarak Sentinel-1 SAR görüntülerinden gemi tespiti gerçekleştirilmiştir. Faster R-CNN, nesne tespitinde başarılı sonuçlar veren bir derin öğrenme modeli olup, Bölge Öneri Ağı (RPN) ve Nesne Algılama Ağı olmak üzere iki temel bileşenden oluşmaktadır. Model, giriş görüntülerinden nesne önerileri üretmekte ve bu önerileri sınıflandırarak gemi tespitini gerçekleştirmektedir. Çalışmada kullanılan veri seti, yüksek mekansal çözünürlüğe sahip Sentinel-1 SAR görüntülerinden oluşmaktadır. SAR görüntüler, hava koşullarından ve aydınlatmadan bağımsız olarak deniz yüzeyinin detaylı bir görüntüsünü sunarak gemi tespiti için uygun bir alternatif oluşturmaktadır. Modelin değerlendirilmesi sonucunda %86.11 doğruluk oranı elde edilmiştir.

Faster R-CNN'nin avantajları, yüksek doğruluk oranı ve SAR görüntülerıyla uyumluluğu iken, zorlukları arasında gemi boyutlarının ve şekillerinin değişkenliği ile deniz yüzeyinin karmaşıklığı yer almaktadır. Sonuçlar, Sentinel-1 verileri ile Faster R-CNN algoritmasının birleştirilmesinin denizcilik güvenliği, gemi izleme ve çevresel analizlerde etkili bir yöntem olduğunu göstermektedir. Ancak, modelin doğrulüğünü artırmak ve küçük nesnelerin tespitinde iyileştirmeler yapmak için daha fazla optimizasyon ve ek veri setleriyle eğitim gerekmektedir.



# MATERİYAL VE YÖNTEM

## ÇALIŞMA ALANI

Bu çalışmada, Mersin Limanı çalışma alanı olarak belirlenmiştir. Mersin Limanı, Akdeniz'in doğu kıyısında yer alan Türkiye'nin en büyük ve en önemli limanlarından biridir. Roma dönemine kadar uzanan köklü bir tarihe sahip olup, günümüzde uluslararası ticaretin merkezi konumundadır. Liman, Avrupa, Orta Doğu ve Asya pazarlarına erişim sağlayan stratejik bir geçit görevi görmekte ve modern altyapısıyla küresel ticarette önemli bir rol oynamaktadır. Ayrıca, Mersin bölgesinin ekonomik kalkınmasına katkı sağlamakta ve istihdam olanakları yaratmaktadır.

## VERİ

Veri seti olarak, Avrupa Uzay Ajansı (ESA) tarafından geliştirilen Sentinel-1 uydu verileri kullanılmıştır. Sentinel-1, Sentetik Açıklıklı Radar (SAR) teknolojisine sahip olup, VH polarizasyonu ile gemi tespiti, arazi örtüsü sınıflandırması ve çevresel analizlerde yaygın olarak kullanılmaktadır. VH polarizasyonu, küçük ve karmaşık yapıya sahip teknelerin tespitini kolaylaştırırken, deniz yüzeyi üzerindeki rüzgar yönü ve hızını belirlemeye de olanak tanımaktadır. Bu özellikleri sayesinde, deniz trafiği yönetimi, arama kurtarma operasyonları ve çevresel izleme gibi çeşitli uygulamalar için değerli bir veri kaynağı sağlamaktadır.

## YÖNTEM

Bu çalışmada, SAR görüntülerinden gemi tespiti ve takibi için SARfish algoritması ve Faster R-CNN modeli kullanılmıştır. SARfish algoritması, SAR görüntülerini ön işleyerek gürültüyü azaltır ve Faster R-CNN ile nesne tespiti yaparak gemileri belirler.

Faster R-CNN modeli, Bölge Öneri Ağı (RPN) ve Sınıflandırma Ağı olmak üzere iki bileşenden oluşur. RPN, potansiyel nesne bölgelerini belirleyip bunlara nesnellik puanı atarken, sınıflandırma ağı bu bölgeleri sınıflandırarak gemi tespitini gerçekleştirir.

Bu yöntem, deniz gözetimi, gemi trafiği yönetimi ve çevresel izleme gibi alanlarda kullanılabilir.

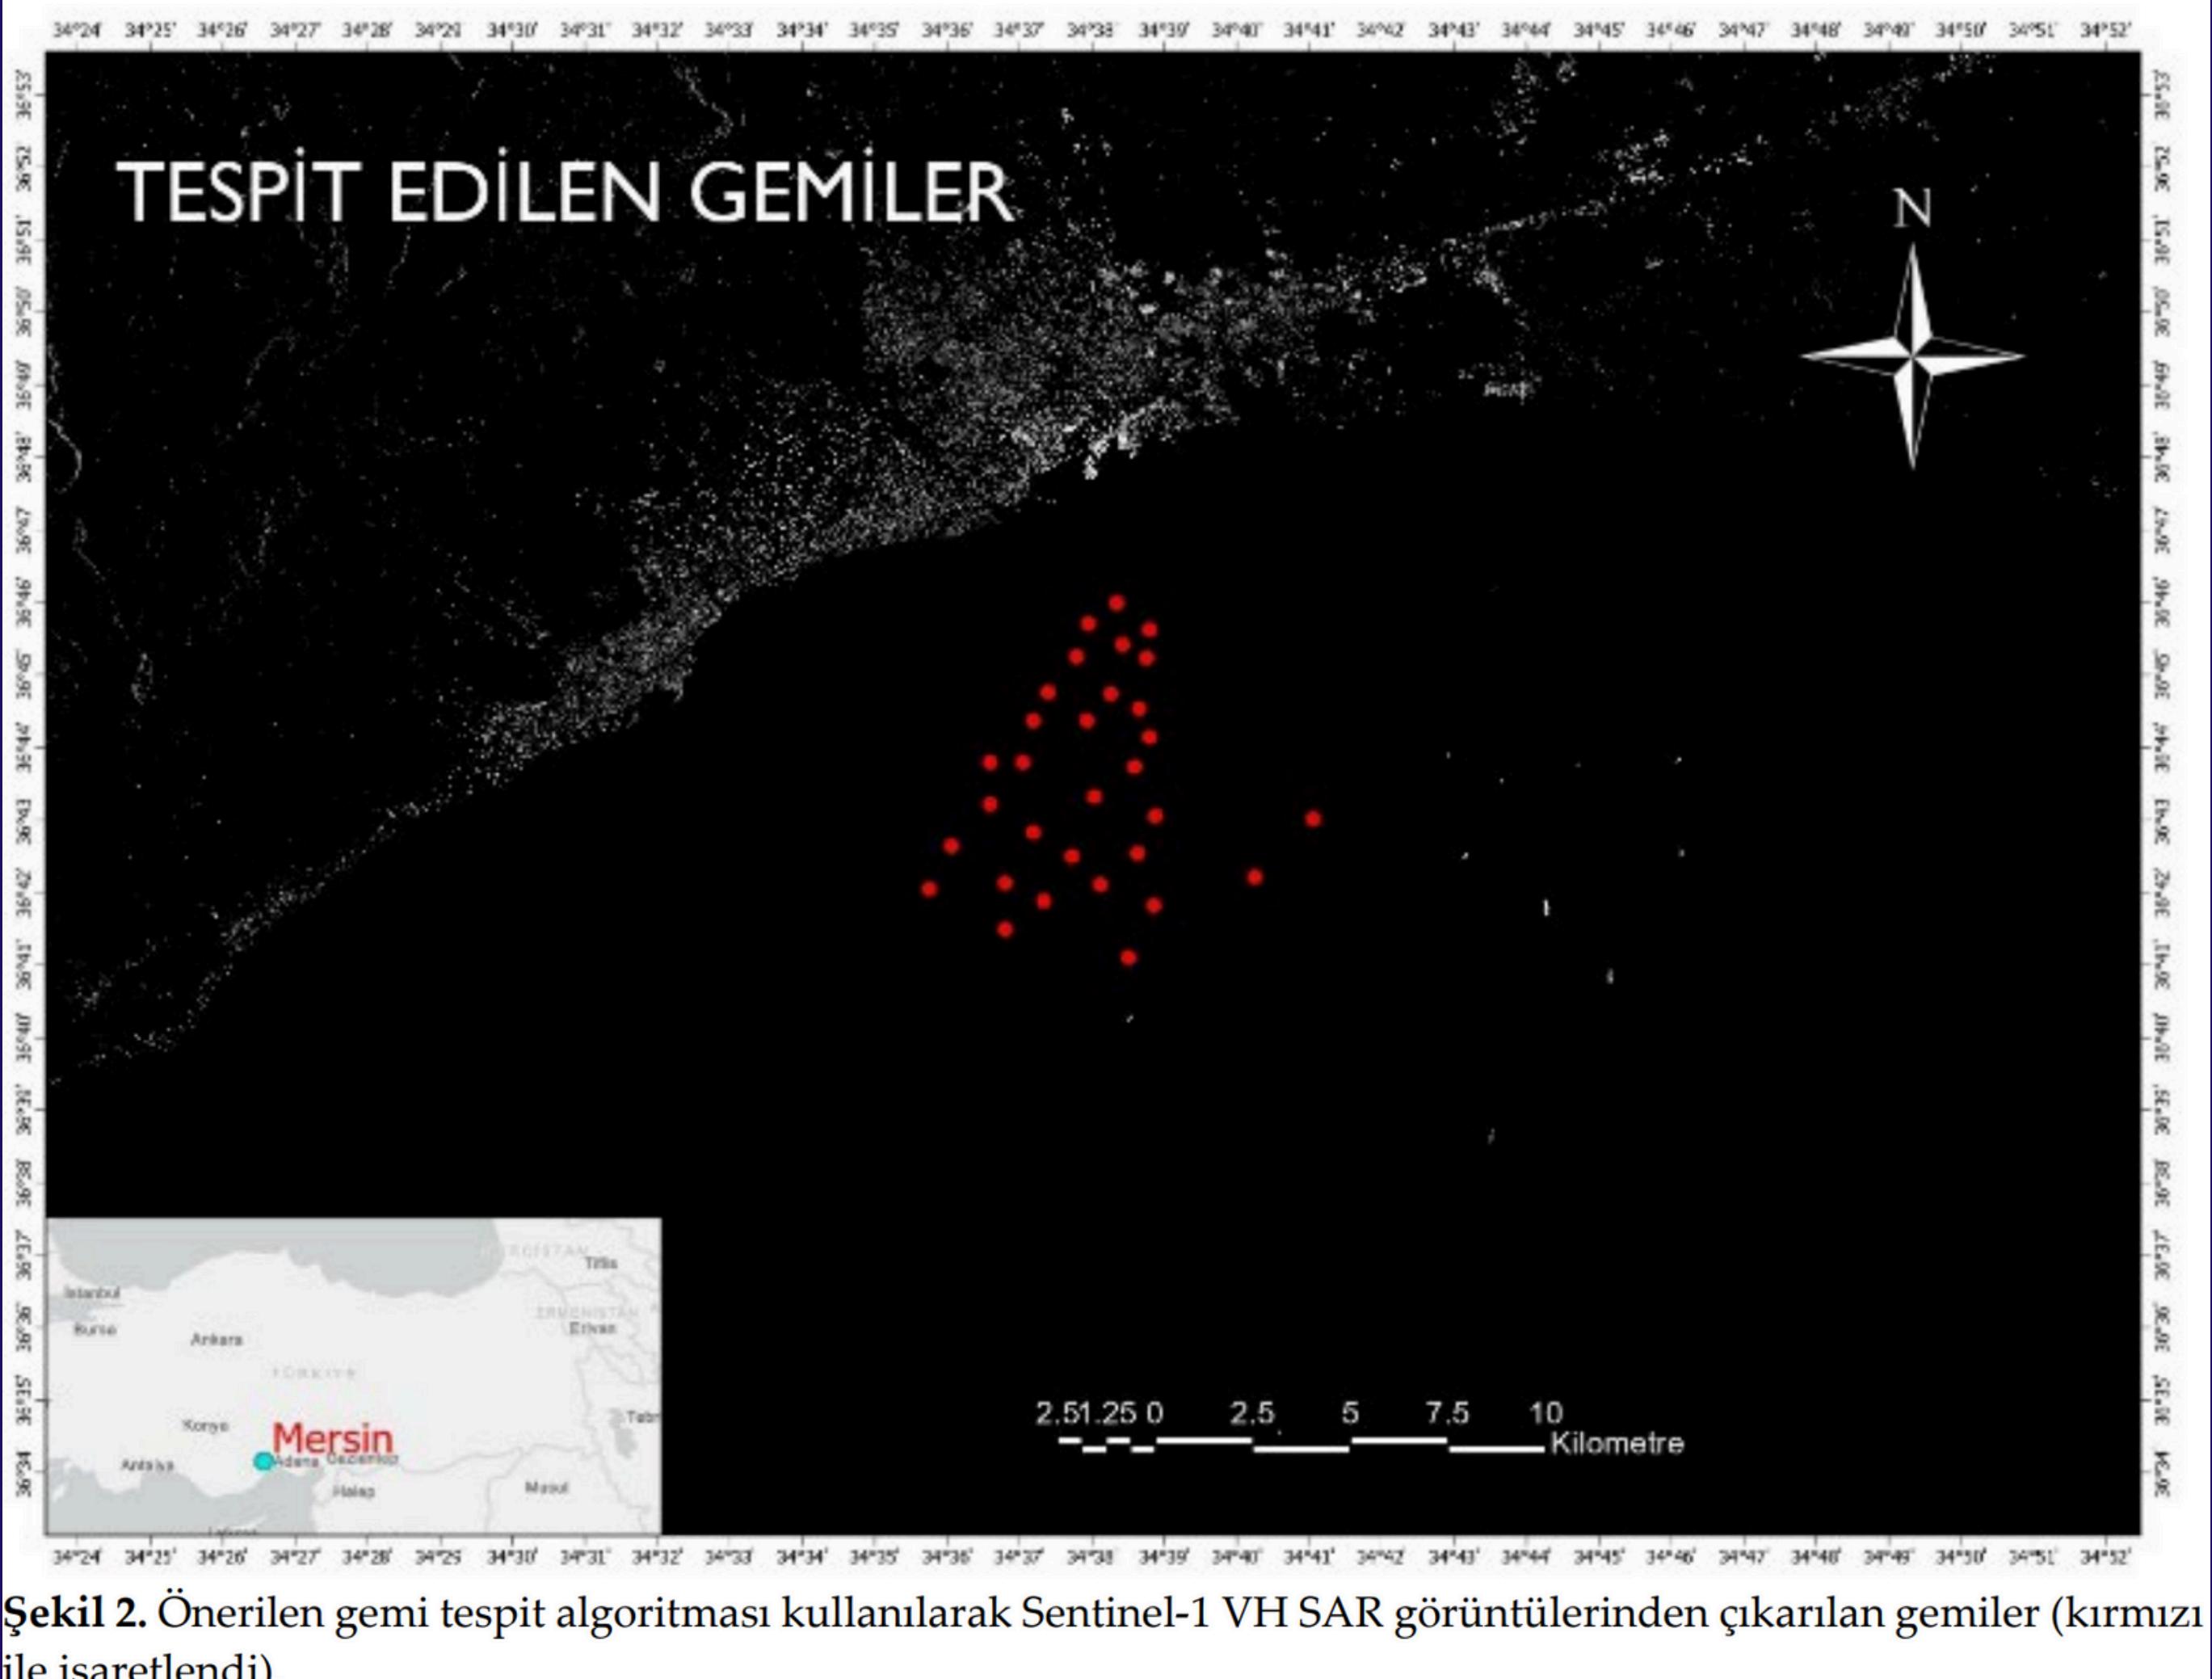
Ortalama %92.9 doğruluk oranı ile yüksek başarı göstermiştir. Açık kaynak yapısı sayesinde deniz güvenliği ve denizcilik uygulamalarında geniş kullanım potansiyeline sahiptir.

## BULGULAR

Bu çalışmada geliştirilen Faster R-CNN tabanlı gemi tespit algoritması, Sentinel-1 VH SAR görüntülerine uygulanmış ve çeşitli gemi türlerini başarıyla tespit etmiştir. Konvolüsyonel sinir ağları ve bölge öneri ağlarının birleşimiyle, küçük balıkçı teknelерinden büyük kargo gemilerine kadar farklı boyutlardaki gemiler yüksek doğrulukla belirlenmiştir.

Elde edilen %86.11 doğruluk oranı, algoritmanın güvenilirliğini ortaya koyarken, %84.54 kesinlik ve %89.03 geri çağrıma değerleri, yanlış pozitif ve yanlış negatif oranları arasında dengeli bir sonuç sağlamıştır. Tespit edilen gemiler harita üzerinde gösterilmiş ve deniz trafiği analizinde kullanılabilecek bir dağılım haritası oluşturulmuştur. Yanlış pozitif oranının düşük olması, algoritmanın görüntüdeki diğer nesneleri gemi olarak hatalı sınıflandırdığını göstermektedir.

Bu bulgular, geliştirilen algoritmanın deniz gözetimi, gemi trafiği yönetimi ve çevresel analizler için etkili bir araç olarak kullanılabilirliğini göstermektedir.(Şekil 2)



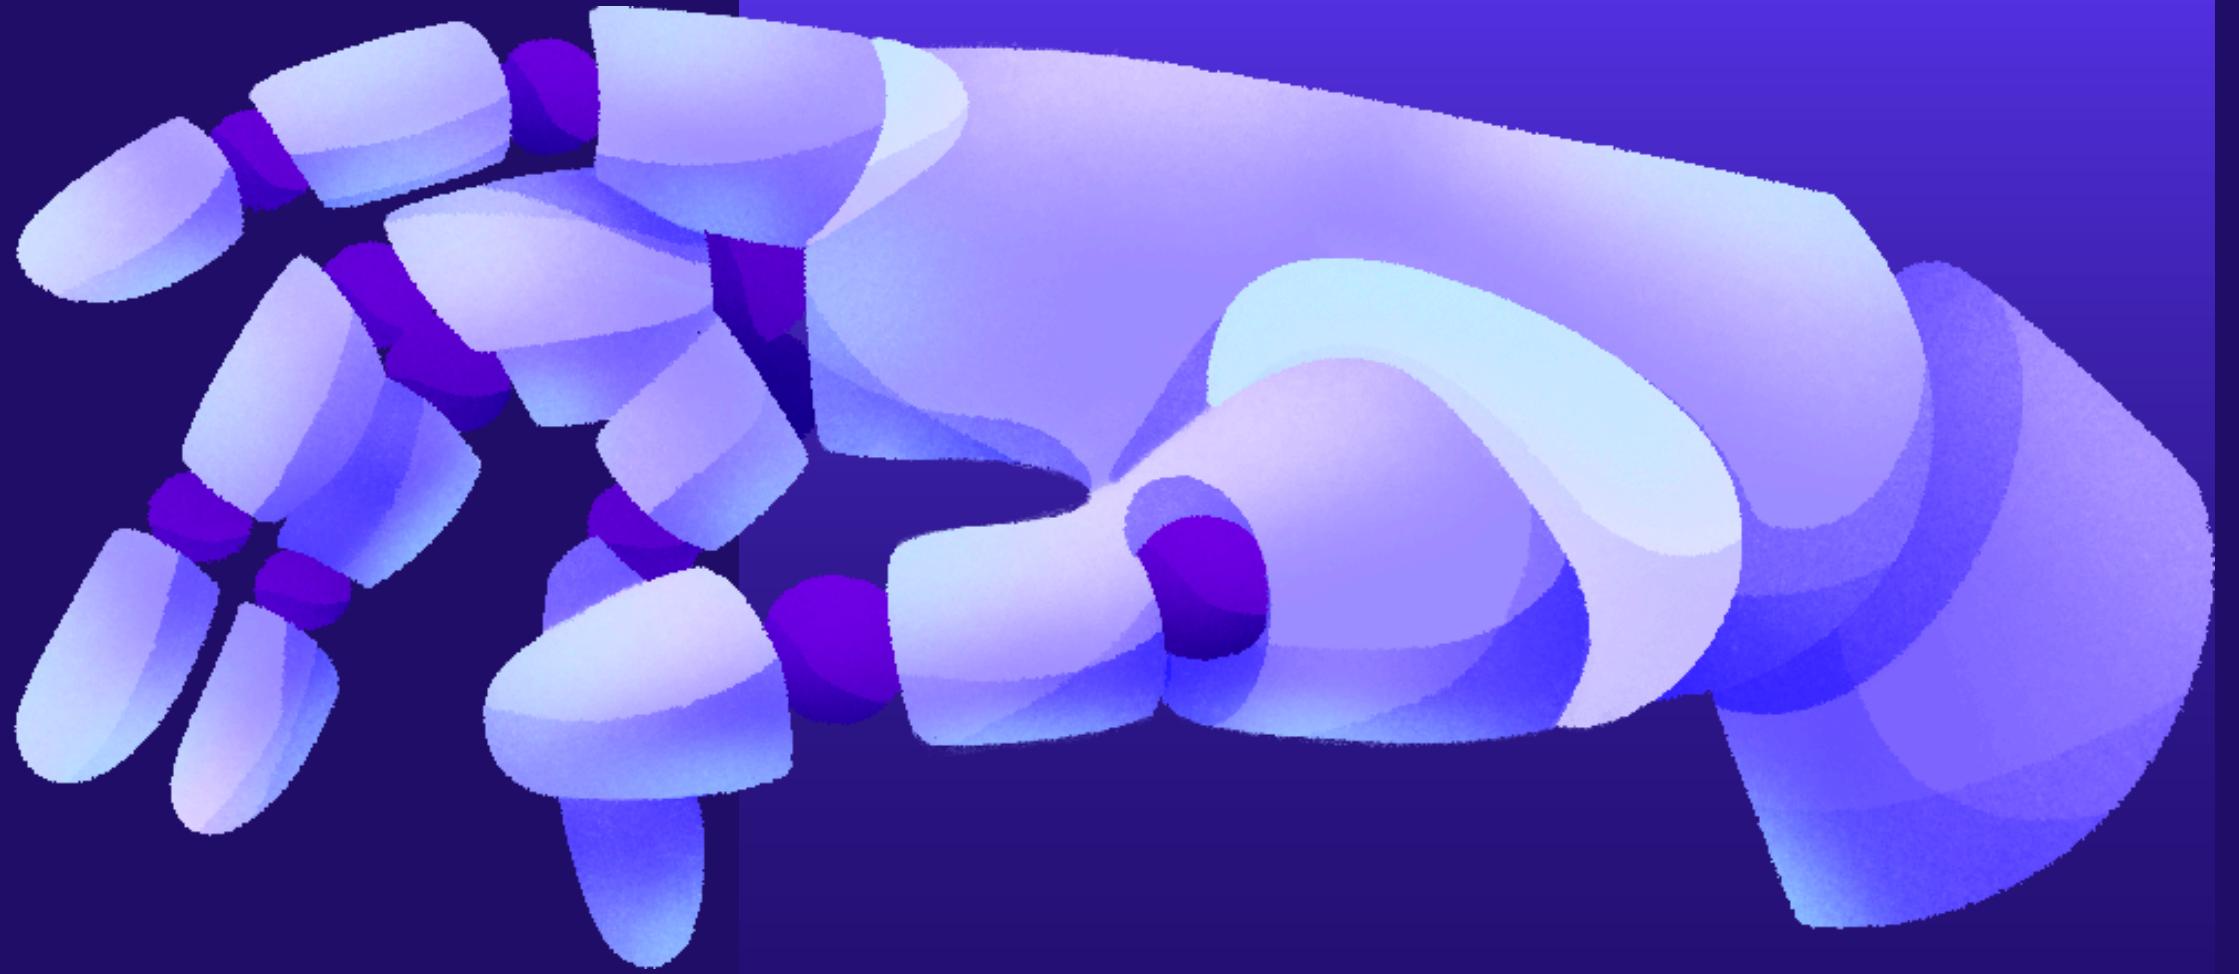
# SONUÇLAR

Bu çalışmada, Sentinel-1 VH SAR görüntülerini kullanılarak Faster R-CNN tabanlı açık kaynaklı bir gemi algılama algoritmasının potansiyeli araştırılmıştır. Önceki çalışmalar genellikle optik görüntüler veya geleneksel yöntemlerle sınırlı kalırken, bu çalışma derin öğrenme tekniklerini SAR görüntülerıyla birleştirerek gemi tespitinin doğruluk ve güvenilirliğini artırmayı hedeflemiştir.

Geliştirilen algoritma, yüksek doğruluk ve düşük yanlış pozitif oranları ile gerçek dünya denizcilik uygulamaları için uygun bulunmuştur. Farklı boyut ve türdeki gemileri başarıyla tespit etmesi, yöntemin çok yönlü ve farklı denizcilik senaryolarına uyarlanabilir olduğunu göstermektedir.

Sonuçlar, SAR görüntülerinin ve derin öğrenme algoritmalarının gemi tespitinde etkin bir şekilde kullanılabileceğini kanıtlamakta ve bu alandaki araştırmalara önemli katkılar sunmaktadır. Bu çalışma, deniz emniyeti, güvenliği ve çevresel izleme için daha doğru ve güvenilir gemi tespit algoritmalarının geliştirilmesine zemin hazırlamakta ve derin öğrenme ile SAR görüntülerinin birleşimini teşvik eden bir model sunmaktadır.





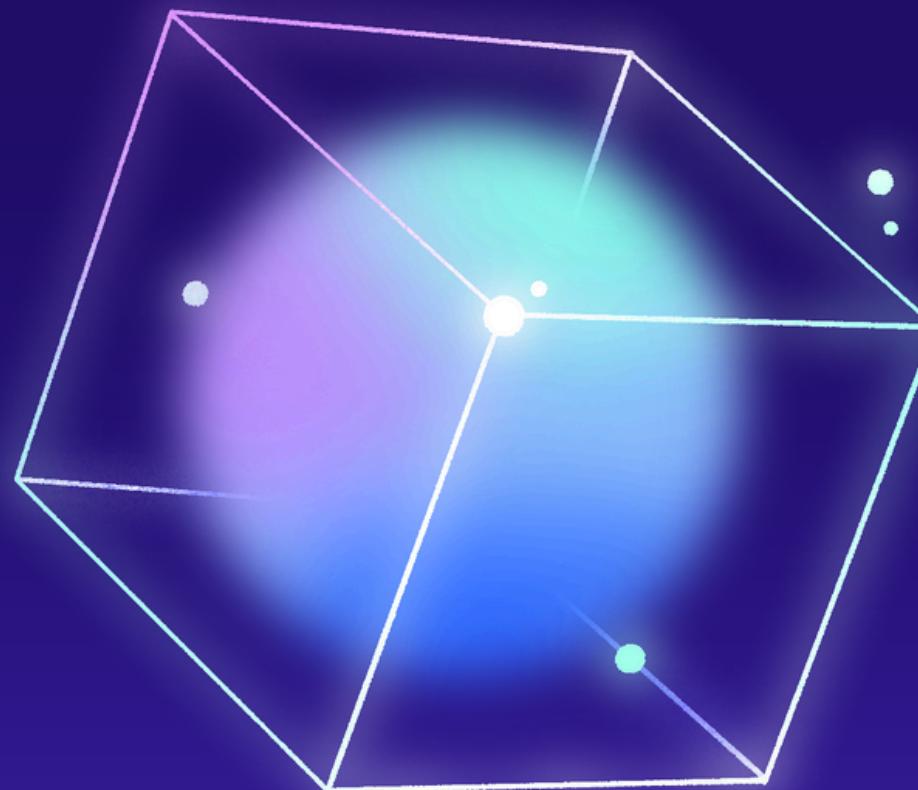
# MASK R-CNN İLE UYDU GÖRÜNTÜLERİNDEN GEMİ TESPİTİ

...

# ÖZET

Bu çalışmada, optik uydu görüntülerinde gemi tespiti için Mask R-CNN yöntemi kullanılmıştır. Konvolüsyonel sinir ağları (CNN) ve uydu görüntüleme teknolojilerindeki gelişmeler, gemi tespitinde önemli ilerlemeler sağlamıştır. Çalışmanın amacı, Mask R-CNN'nin gemi tespit performansını ve sınırlarını değerlendirmektir.

1 metre mekânsal çözünürlüğe sahip 1838 uydu görüntüsü kullanılarak bir veri seti oluşturulmuş ve gemiler GIS yazılımı ile maskelenerek etiketlenmiştir. Sonuçlar, Mask R-CNN'nin zorlu koşullarda bile gemileri başarıyla tespit edebildiğini, ancak birbirine yakın konumlanmış gemileri ayırt etmede bazı kısıtlamalara sahip olduğunu göstermiştir.  
**Anahtar Kelimeler:** Derin Öğrenme, Gemi Tespiti, Mask R-CNN, Uydu Görüntüleri



• • •

# GİRİŞ

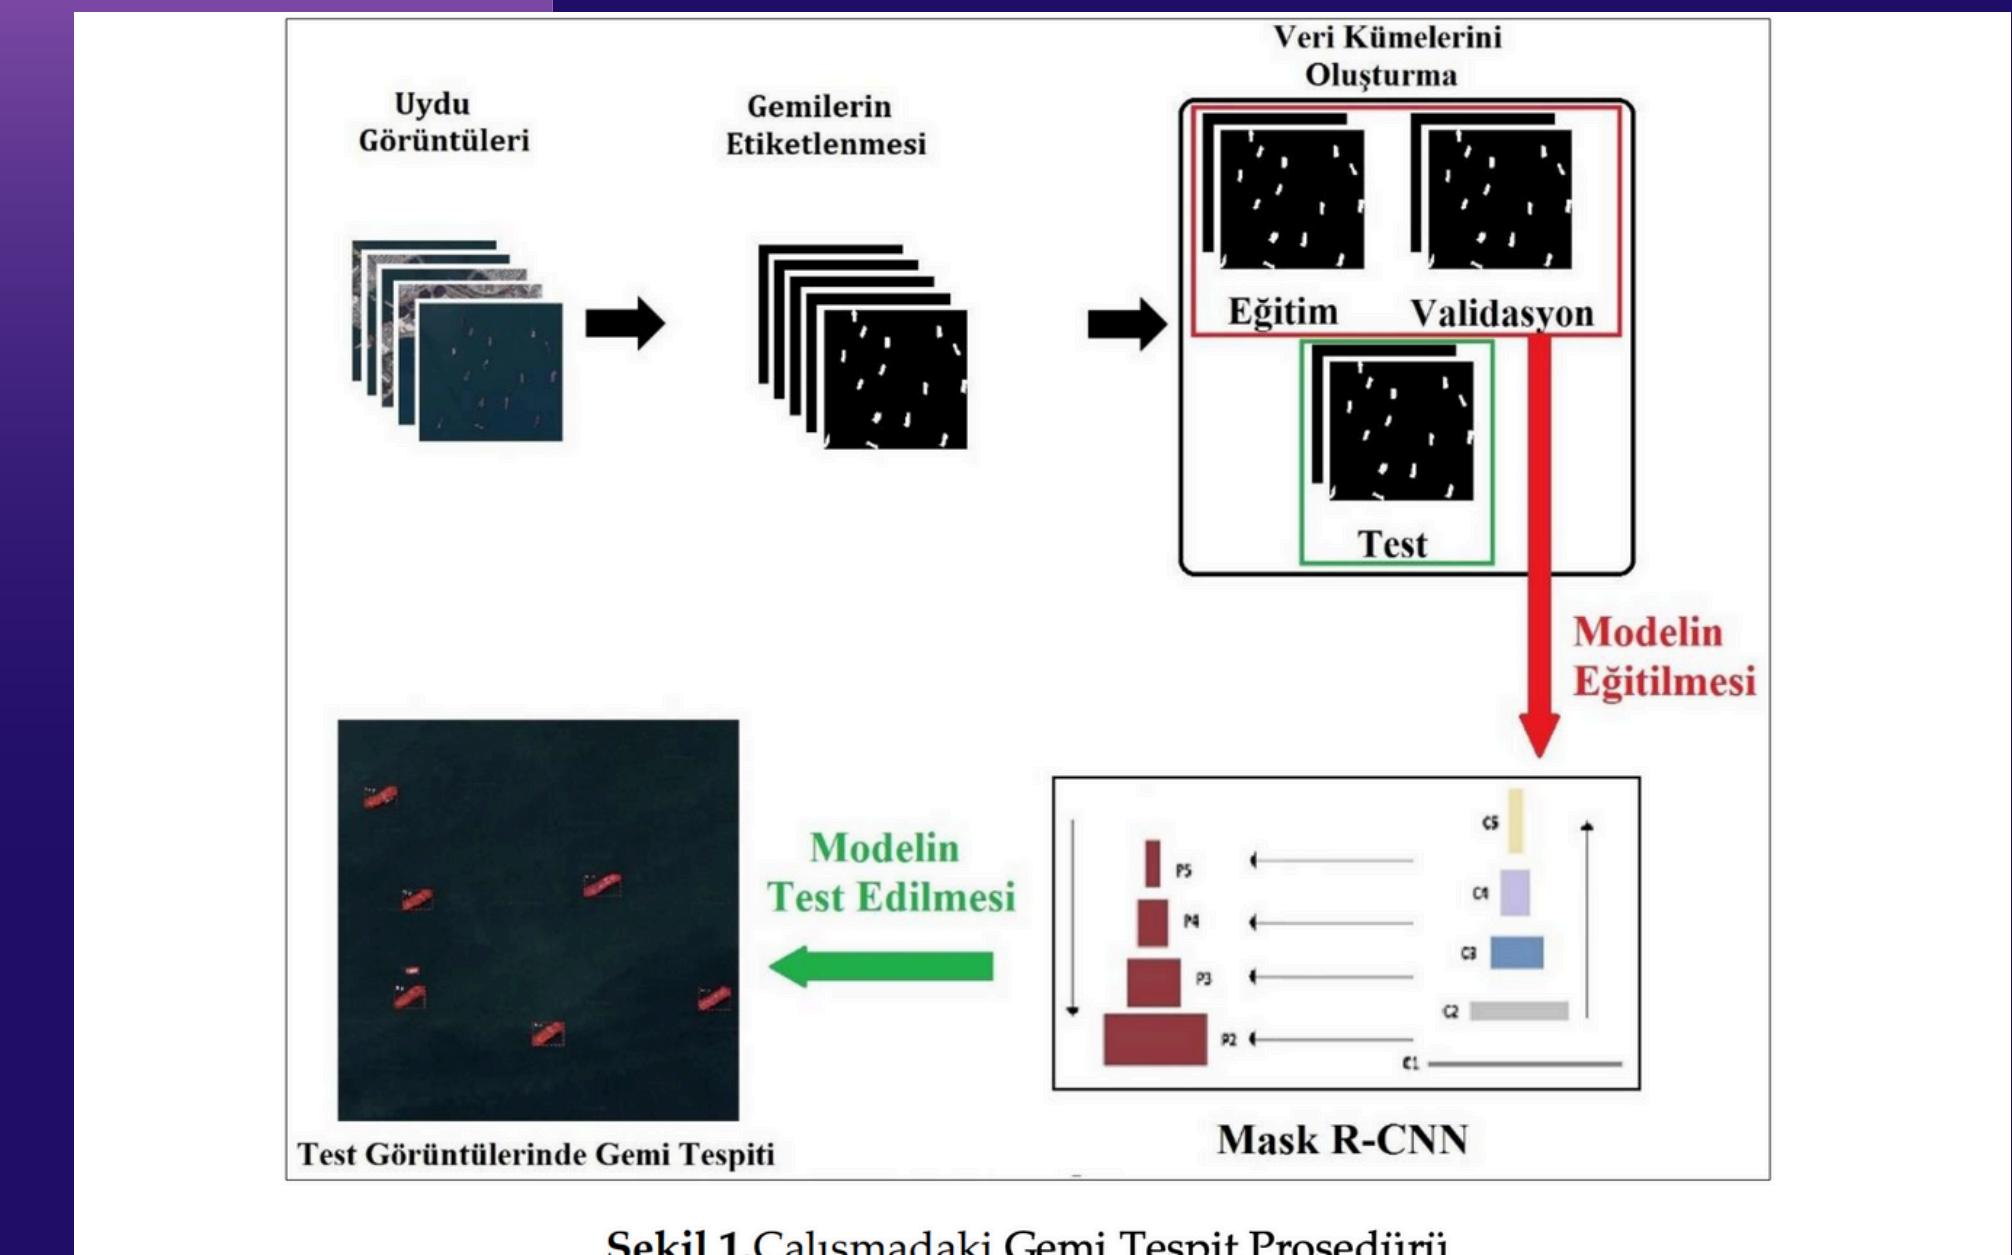
Bu çalışmada, uydu görüntülerinde gemi tespiti için Mask R-CNN yöntemi kullanılacaktır. Gemi tespiti, deniz güvenliği ve taşımacılığı gibi alanlarda önemlidir ve son yıllarda yüksek çözünürlüklü uydu görüntüleriyle bu tespitler daha doğru hale gelmiştir. Geleneksel makine öğrenimi yöntemleri, girdilerin eğitim standardından sapması durumunda performans kaybı yaşarken, konvolüsyonel sinir ağları (CNN) bu sorunu aşarak daha başarılı sonuçlar vermektedir.

Mask R-CNN, nesne konumlarını öğrenme yoluyla belirleyen bir yöntemdir ve nesneleri sınırlayıcı kutular ve maskelerle işaretler. Bu çalışmada, gemilerin maskelerle etiketlendiği bir veri seti oluşturulacak ve modelin parametreleri deneylerle optimize edilecektir. Sonuçlar, modelin başarısını değerlendirmek için çeşitli metriklerle ölçülerek, gemi tespitindeki verimlilik artırılacaktır



# MATERYAL VE YÖNTEM

Bu çalışmada Şekil 1'de gösterilen bir akış süreci izlenmiştir. Ham görüntülerden başlayan süreçte öncelikle görüntüler işlenip etiketlenmekte ve veri setleri oluşturulmaktadır. Ardından bu veriler kullanılarak model eğitilmekte ve test görüntülerdeki gemilerin tespitiyle süreç tamamlanmaktadır. Bu başlıkta sırasıyla çalışmada kullanılan verilere, gemi tespiti için önerilen modele, modelin eğitimine dair detaylara ve tespit değerlendirme metriklerine yer verilmektedir.



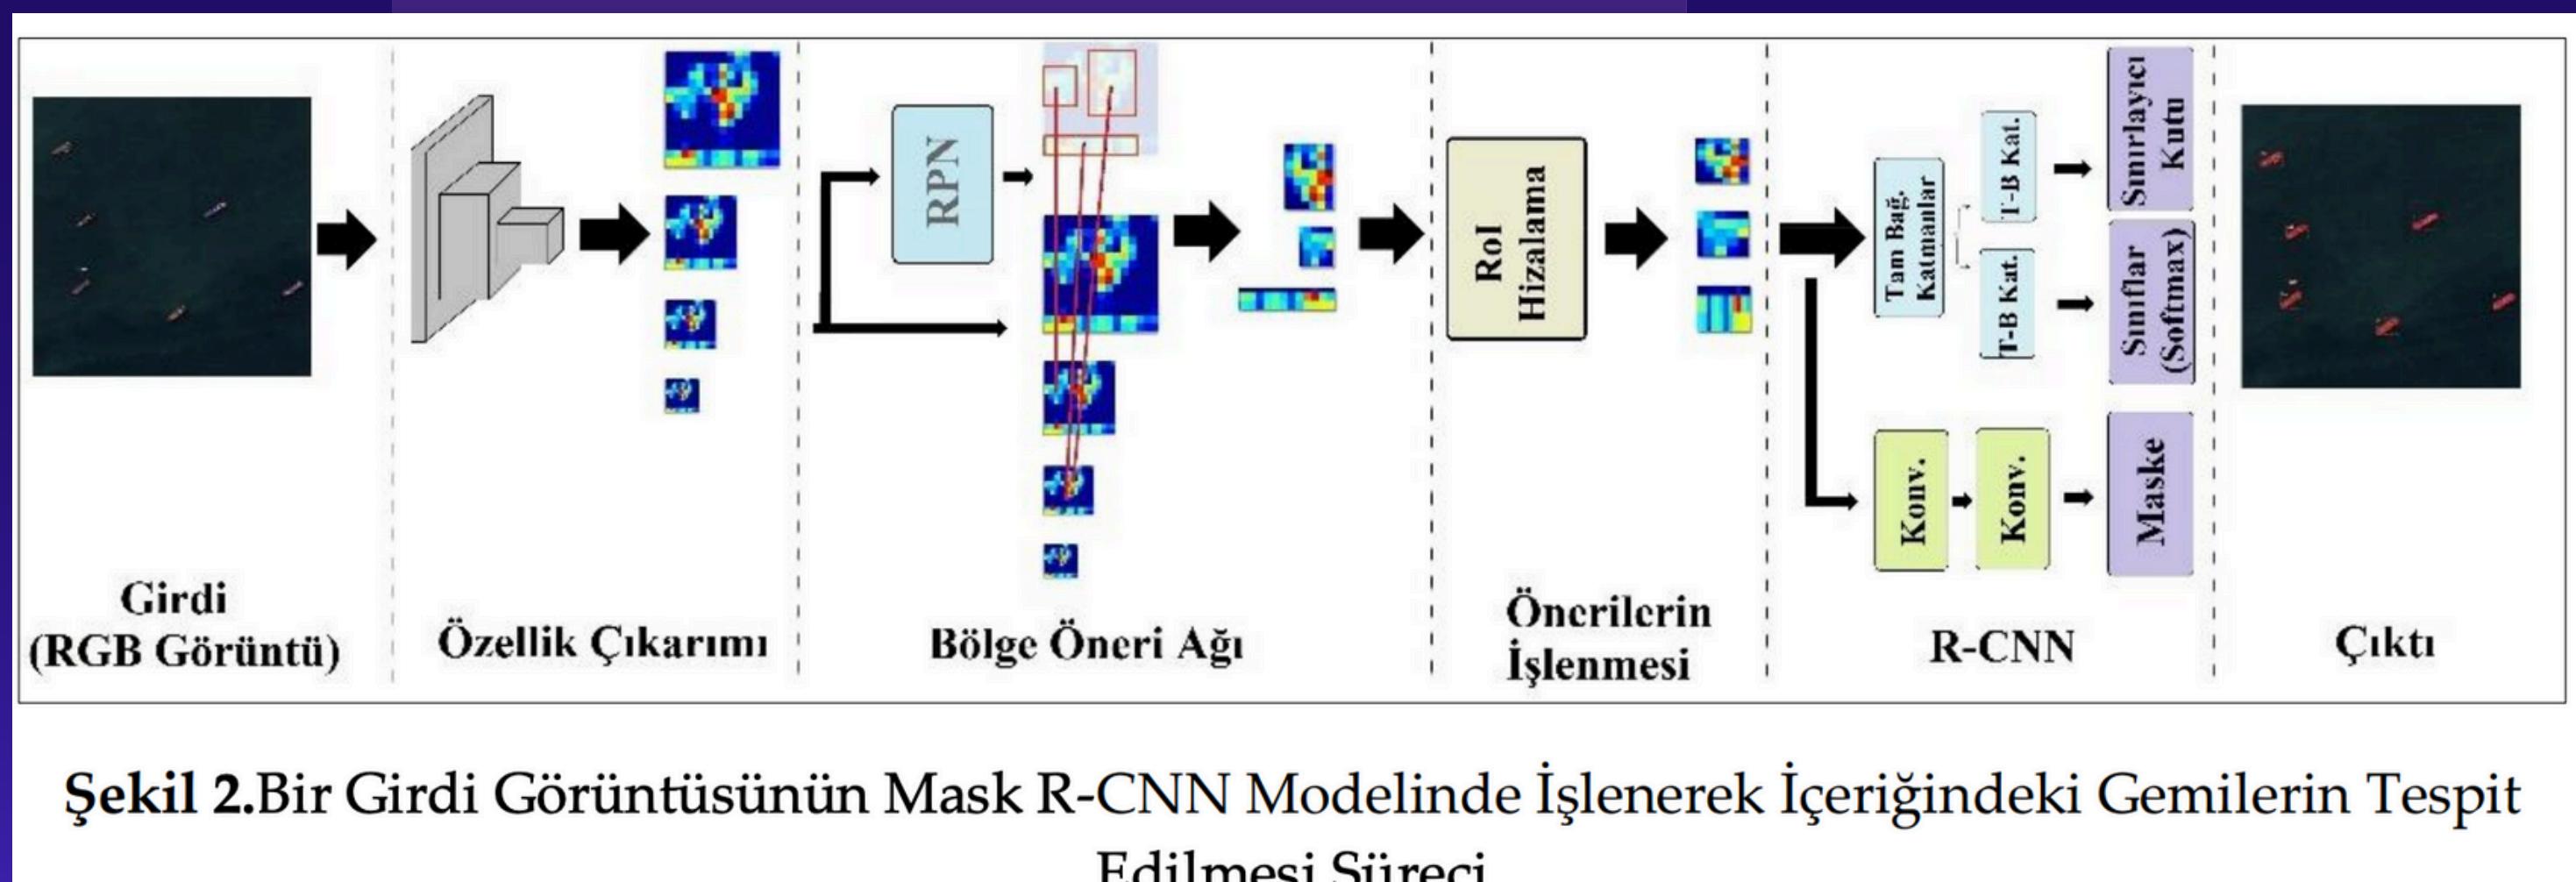
Şekil 1. Çalışmadaki Gemi Tespit Prosedürü

## VERİ SETİ

Çalışmada kullanılan veriler Google Earth tarafından sağlanan 1 metre mekânsal çözünürlüklü, geotif formatındaki RGB uydu görüntüleridir. Açık denizlerden, kıyı yakınlarından ve iç sularдан örnekler bulunmaktadır. Süreçte öncelikle her biri 768x768 piksel büyüğünde toplam 1838 görüntü elde edilmiştir. Bunlar kullanılarak eğitim, validasyon ve test veri setleri oluşturulmuştur (Tablo 1). Görüntülerdeki toplam 3279 gemi bir GIS yazılımı kullanılarak sayısallaştırılmıştır. Oluşturulan eğitim ve validasyon setleri kullanılarak model eğitilmiş ve doğrulaması yapılmıştır. Sonrasında, eğitilen model test görüntüleri üzerinde çalıştırılarak tespit performansı hesaplanmıştır.

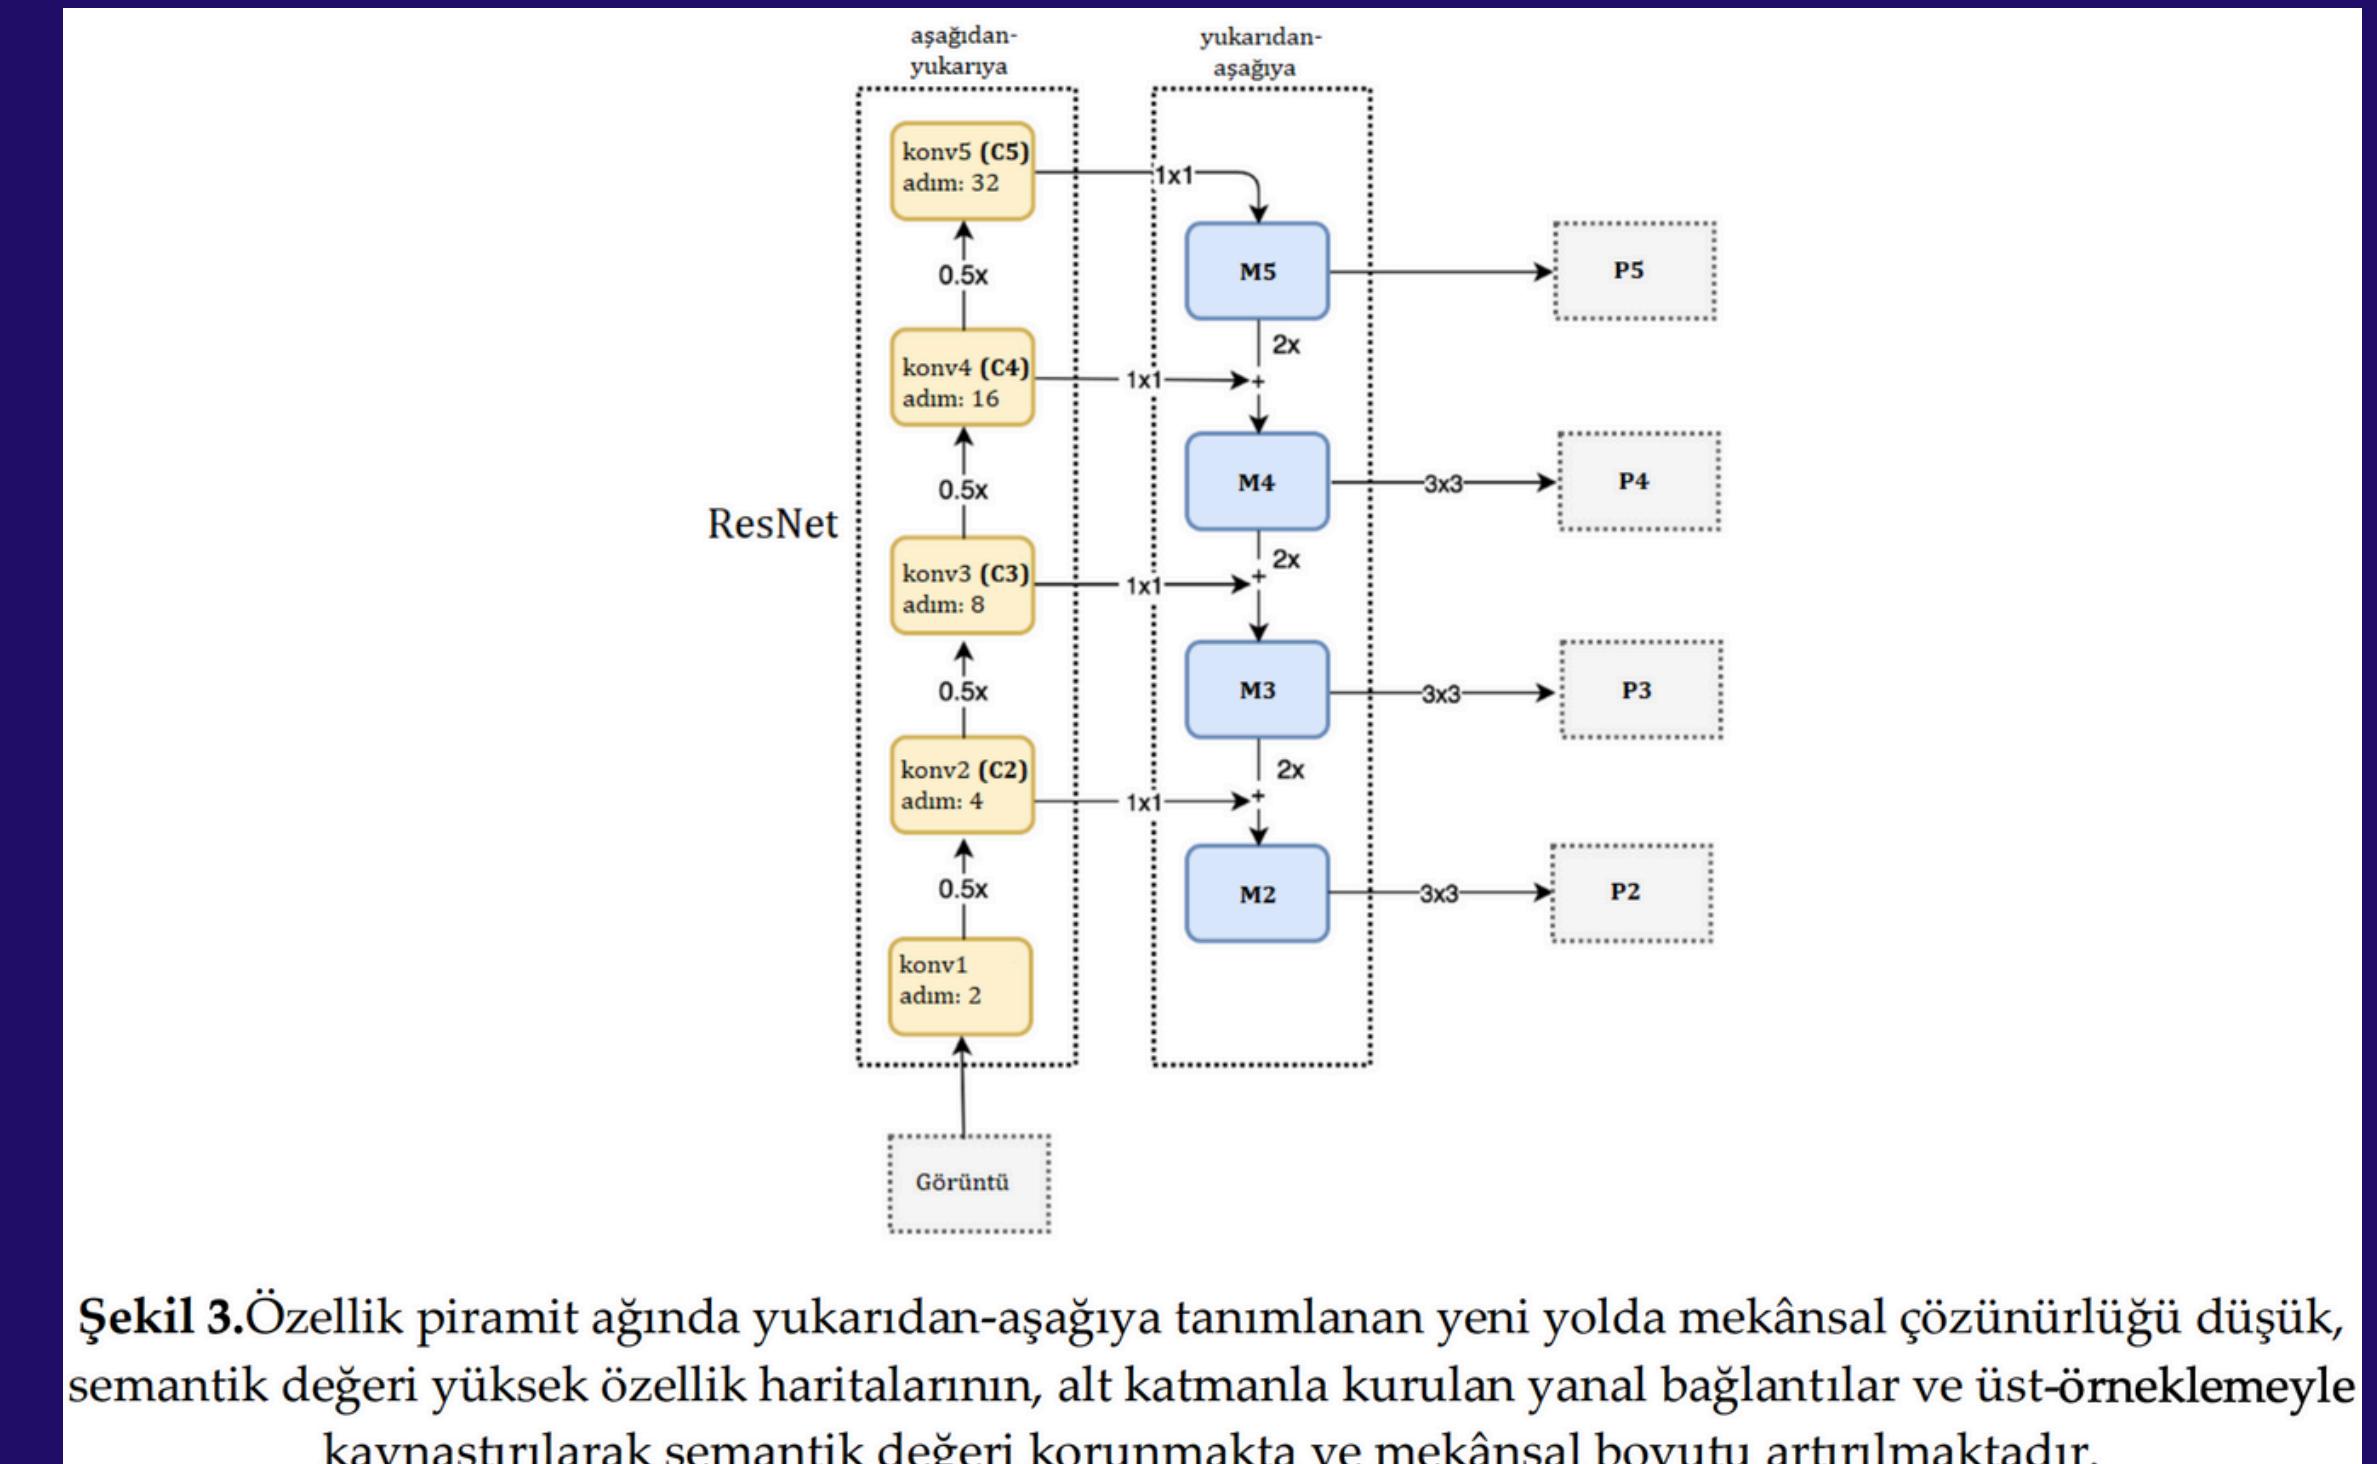
## YÖNTEM

Bu çalışmada uydu görüntülerinde yer alan gemileri tespit etmek üzere Mask R-CNN modeli kullanılmıştır. Girdi görüntüsü bu modelde Şekil 2'de gösterilen aşamalardan geçerek işlenmektedir. Mask R-CNN çıktı olarak, tespit ettiği gemilerin maskelerini üretmekte, sınırlayıcı kutularını oluşturmaktır ve her tespitin olasılık değerini hesaplamaktadır.



Mask R-CNN, nesne tespiti için dört ana modülinden oluşur: özellik çıkarım ağı, bölge öneri ağı, öneri işleme modülü ve bölge-tabanlı konvolüsyonel sinir ağı (R-CNN). Özellik çıkarımı, ön-eğitimli bir CNN kullanılarak görüntünden konvolüsyonel özellik haritalarının elde edilmesini sağlar. Bu süreçte, mekânsal boyutlar küçültülürken özellikler soyutlanarak daha kullanışlı hale getirilir.

Bu çalışmada kullanılan Mask R-CNN sürümünde, özellik çıkarımı için Özellik Piramit Ağı (FPN) kullanılmıştır. FPN, yüksek çözünürlüklü katmanları derin katmanlarla kaynaştırarak, nesne tespitinde daha verimli bir yapay zeka modeli sunar.



**Şekil 3.** Özellik piramit ağında yukarıdan-aşağıya tanımlanan yeni yolda mekânsal çözünürlüğü düşük, semantik değeri yüksek özellik haritalarının, alt katmanla kurulan yanal bağlantılar ve üst-örneklemeyle kaynaştırılarak semantik değeri korunmakta ve mekânsal boyutu artırılmaktadır.

Mask R-CNN'de FPN (Özellik Piramit Ağı), nesne tespitini iyileştirmek için aşağıdan-yukarıya ve yukarıdan-aşağıya olmak üzere iki aşamalı bir özellik çıkarım süreci uygular.

- ◆ Aşağıdan-yukarıya yol: Özellik haritaları ( $C_5 \rightarrow C_2$ ) üretilir. Boyutlar küçülürken, semantik bilgi artar.
- ◆ Yukarıdan-aşağıya yol: Daha büyük mekânsal çözünürlükte özellik haritaları ( $M_5 \rightarrow P_2$ ) oluşturulur ve kaynaştırılır.

Bölge Öneri Ağı (RPN), görüntüde nesne olabilecek bölgeleri önerir. Nesne büyüklüğüne göre  $P_2$ ,  $P_3$ ,  $P_4$  veya  $P_5$  seçilir. Öneri güven eşiği, nesnenin belirlenmesinde rol oynar.

Rol Hizalama, önerileri standart boyuta getirerek R-CNN modülüne hazırlar. Son aşamada, nesneler sınıflandırılır, kutular hassaslaştırılır ve maskeler üretilir. Böylece, giriş görüntüsündeki nesneler başarılı şekilde tespit edilir.

## MODEL EĞİTİMİ

Bu çalışmada Mask R-CNN modeli için Waleed'in (2017) Tensorflow ve Keras derin öğrenme çerçevelerinde çalışan GitHub uyarlaması kullanılmıştır. Modelde omurga ağ olarak Common Objects in Context (COCO) veri setiyle ön-eğitim almış ResNet-101 kullanılmıştır. Modelde ikisi RPN, üçü R-CNN için olmak üzere toplam 5 adet kayıp fonksiyonu tanımlıdır. Model, başlangıç değeri 0,001 olan öğrenme oranı kullanılarak toplam 80 bin iterasyonda eğitilmiştir. Eğitimde 0,0001'lik bir ağırlık bozunumu (weight decay) ve 0,9'luk momentum değerleriyle momentumlu Stokastik Gradyan İniş yöntemi ve geriyayılım algoritmaları kullanılmıştır. Deneyler, Ubuntu 16.04 işletim sisteminde Intel i7-6850k işlemcili, 64 GB RAM'e sahip, Nvidia GeForce GTX 1080 Ti ekran kartlı bir bilgisayar kullanılarak gerçekleştirilmiştir

## TESPİT DEĞERLENDİRME METRİKLERİ

Modelin tespit performansı kesinlik, geri getirme ve F1 skoru metrikleri kullanılarak değerlendirilmiştir.

- Kesinlik (Precision): Doğru tahminlerin toplam tahminler içindeki oranıdır ve yanlış alarmların (FP) değerlendirilmesine yardımcı olur.
- Geri Getirme (Recall): Doğru tespitlerin toplam gerçek nesnelere oranıdır ve modelin ne kadar doğru tespit yaptığını ölçer.
- F1 Skoru: Kesinlik ve geri getirme metriklerinin harmonik ortalaması olup, modelin genel başarısını gösterir.

Çalışmada, bir tespit tahmini IoU değeri 0,5'ten büyükse doğru tespit (TP), aksi halde yanlış tespit (FP) olarak kabul edilmiştir.

## BULGULAR VE TARTIŞMA

Modelin en uygun güven eşiği belirlenmiş ve 0,5 olarak tespit edilmiştir. Bu eşik değeriyle model:

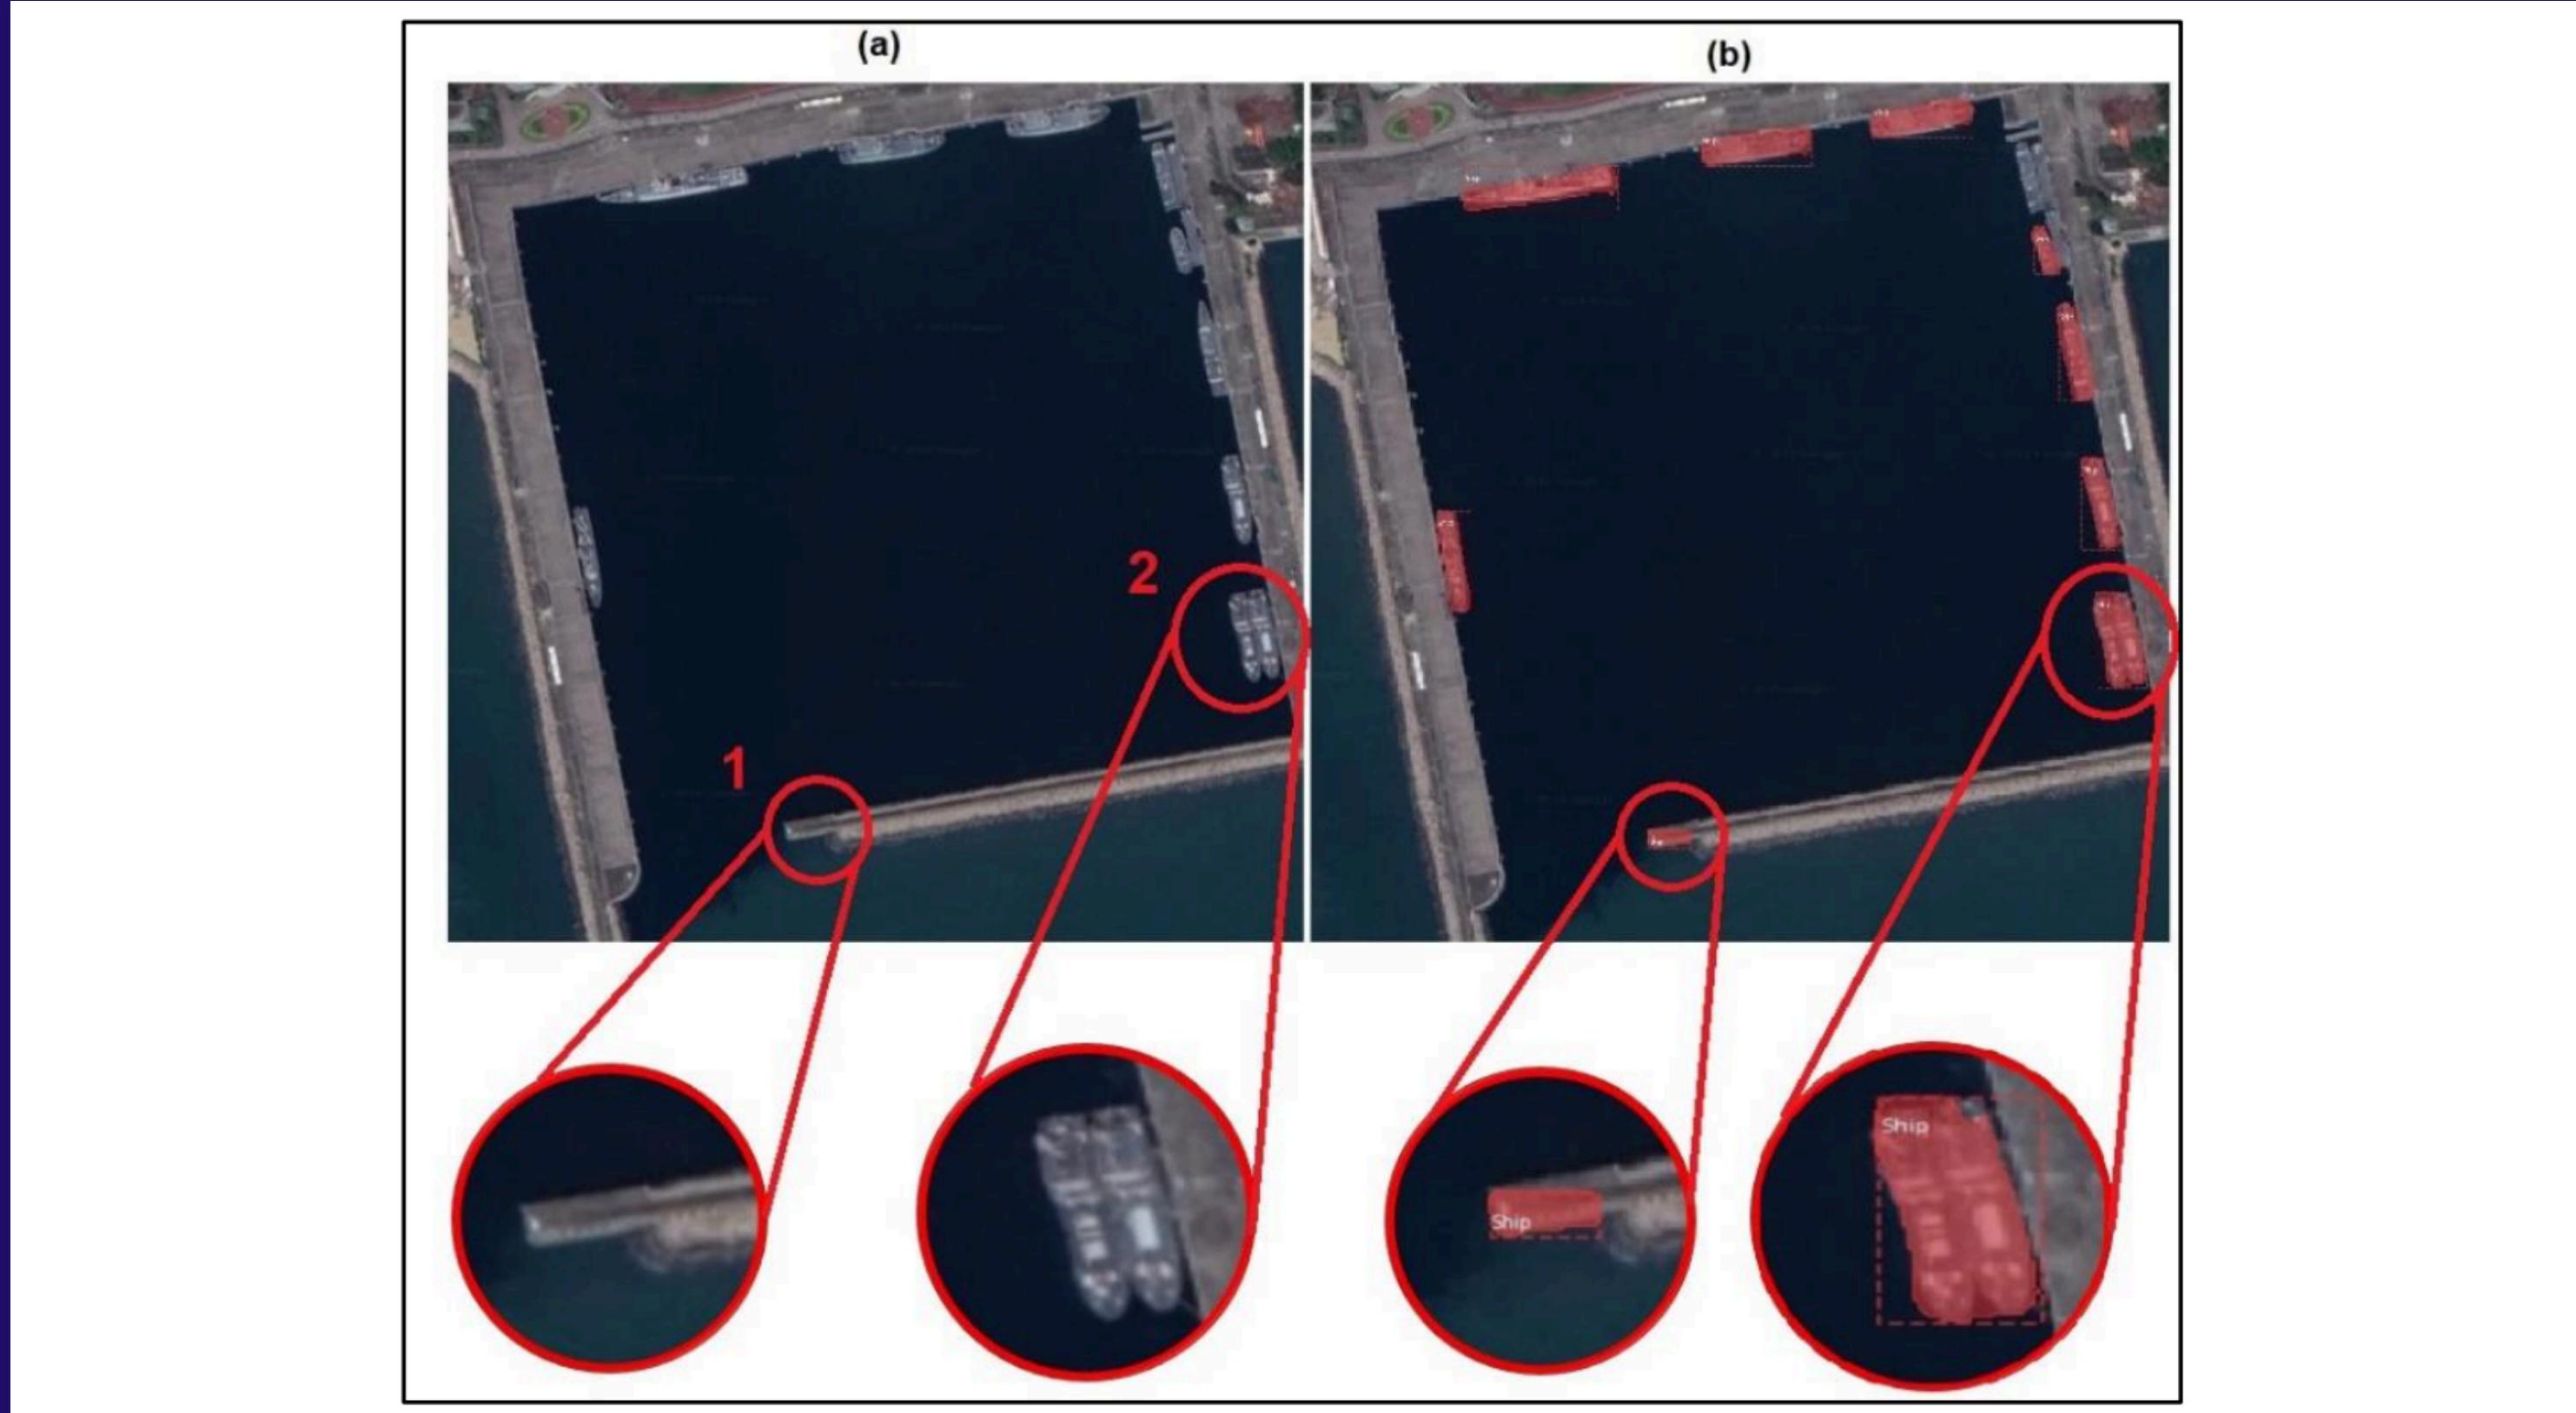
- 604 geminin 558'ini doğru tespit etmiş, 46'sını gözden kaçırılmış ve 58 yanlış alarm üretmiştir.
- Geri getirme (recall): 0,9238, kesinlik (precision): 0,9058, F1 skoru: 0,9148 olarak hesaplanmıştır.

Test görüntülerinde:

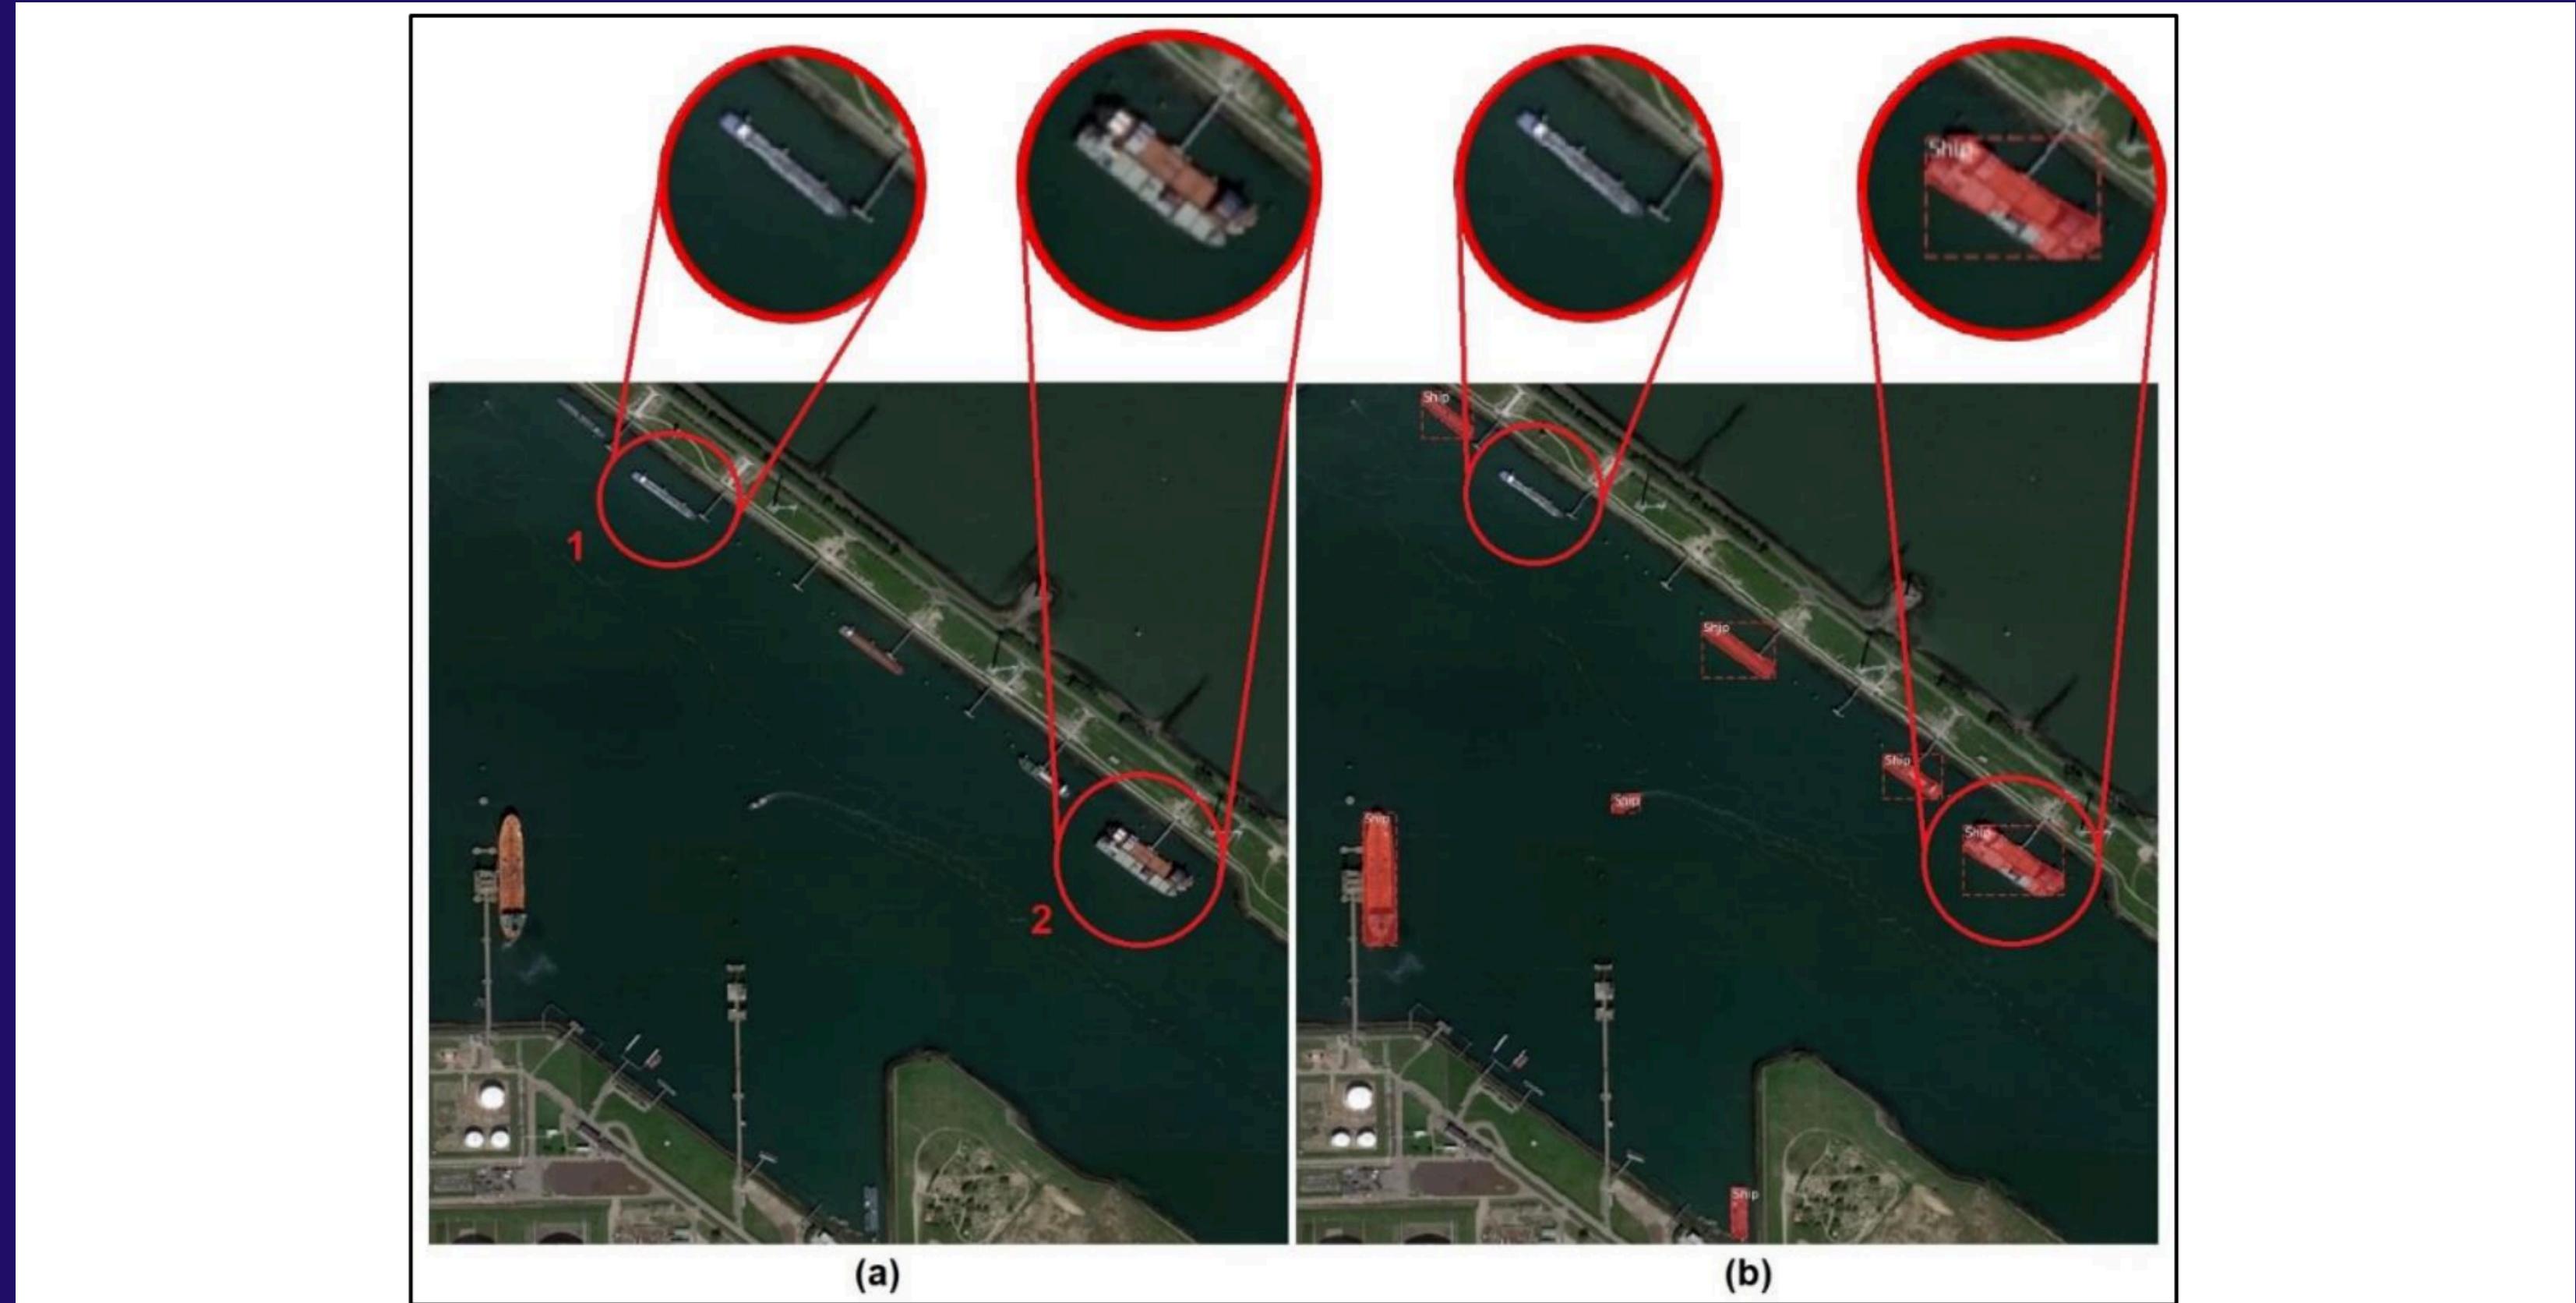
- Singapur Limanı görüntüsünde 8 gemiden 7'si doğru tespit edilmiş, küçük bir gemi gözden kaçırılmıştır.
- Hong Kong askeri limanı görüntüsünde 10 gemiden 8'i doğru tespit edilmiş, 2'si gözden kaçırılmış, ayrıca bir kara parçası yanlışlıkla gemi olarak sınıflandırılmıştır.
- Rotterdam iç limanı görüntüsünde 9 gemiden 7'si doğru tespit edilmiş, 2'si gözden kaçırılmış, bir limana yanaşmış gemi ve yan yana duran iki gemi tek bir gemi olarak işaretlenmiştir.



Şekil 4. Açık Denizde Bulunan Gemileri İçeren Bir Uydu Görüntüsü (a) ve Modelin Bu Görüntü İçin Ürettiği Tespit Sonucu (b)



**Şekil 5.**Hong Kong'daki Askeri Bir Limana Yanaşmış Gemileri İçeren Bir Uydu Görüntüsü (a) ve Modelin Bu Görüntü İçin Ürettiği Tespit Sonucu (b)

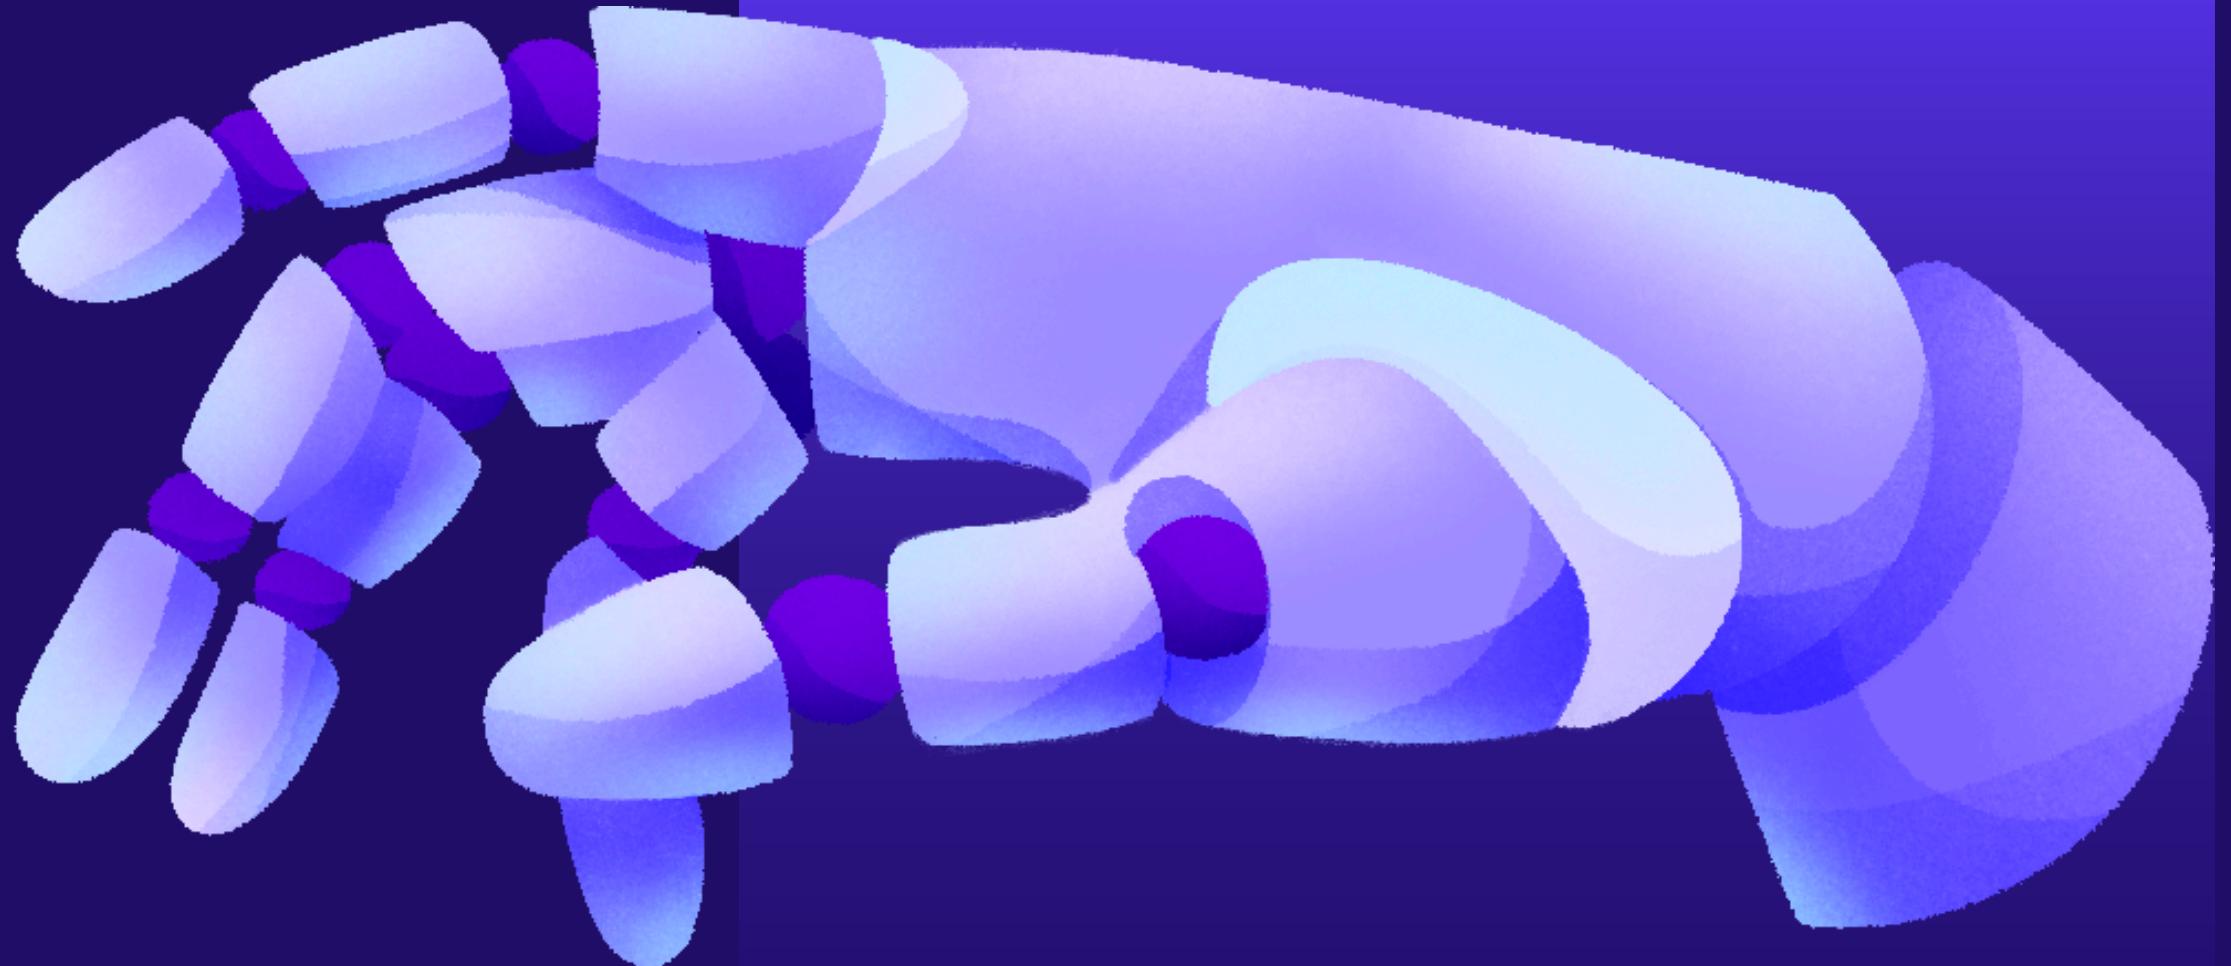


**Şekil 6.**Rotterdam'daki Bir İç Limanda Bulunan Gemileri İçeren Bir Uydu Görüntüsü (a) ve Modelin Bu Görüntü İçin Ürettiği Tespit Sonucu (b)

# SONUÇLAR

Çalışmada bölge-tabanlı bir nesne tespit modeli olan Mask R-CNN yöntemiyle uydu görüntülerindeki gemiler tespit edilmiş ve çeşitli metriklerle performansı değerlendirilmiştir. Mask R-CNN'nin tespit işleminden kullanılmasıyla önceki yaklaşımlardan farklı olarak gemiler görüntülerde sınırlayıcı kutulara ilave olarak maskelerle de işaretlenmiştir. Sonuçlara göre, 0,5'lik bir güven eşiği ile çalıştırılan Mask RCNN modeli test görüntülerinde yer alan 604 geminin 558'ini doğru şekilde tespit etmiş ve 58 yanlış alarm üretmiştir. Modelin çeşitli görüntüler için ürettiği tespitler incelendiğinde, özellikle birbirine yakın konumlanmış gemiler söz konusu olduğunda ya hepsinin tek bir gemi olarak işaretlendiği ya da gemilerden birinin veya birkaçının gözden kaçırıldığı görülmektedir. Diğer taraftan, daha az sayıda olmakla beraber bazı karasal bölgelerin kimi zaman model tarafından gemi olarak algılandığı, kimi zaman da karaya yanaşmış bazı gemilerin gözden kaçırıldığı gözlenmiştir. Gelecek çalışmalarında bu hataların altında yatan sebeplerin ortaya çıkarılmasına yönelik deneyler ve Mask R-CNN'nin aynı test verisi üzerinde farklı modellerle karşılaştırılması planlanmaktadır.

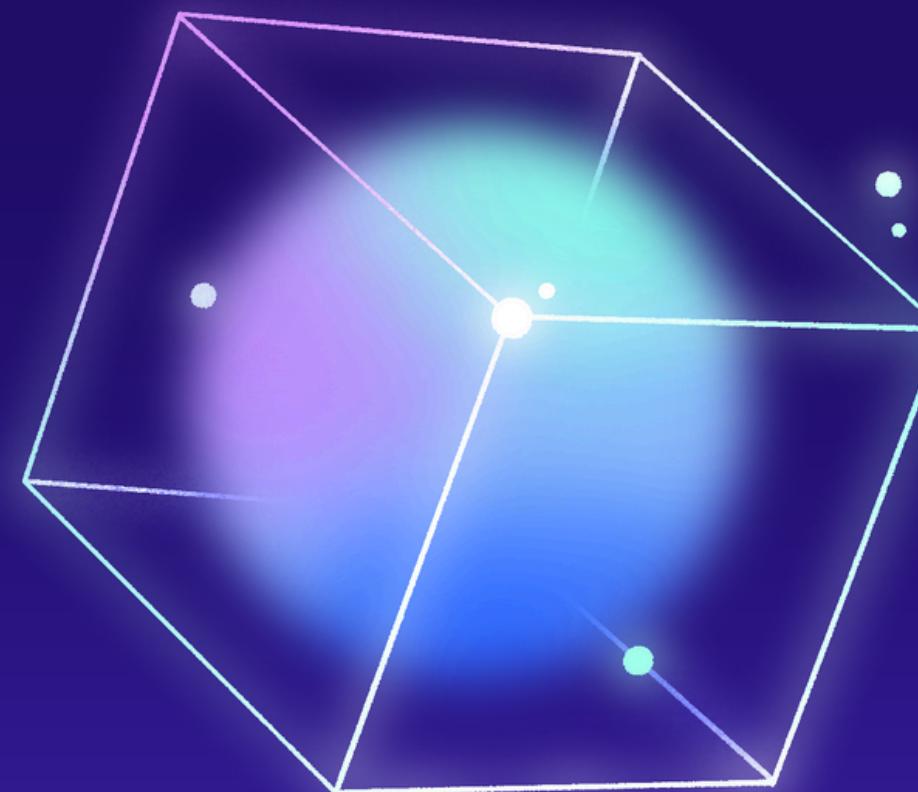




# GEMİ TESPİTİ UYGULAMASINDA YOLOV8 VE YOLOV9 ALGORİTMALARININ PERFORMANS DEĞERLENDİRMESİ

...

# ÖZET



Bu çalışma, uzaktan algılama ve derin öğrenme teknikleriyle gemi tespiti ve sınıflandırmasını ele almaktadır. YOLOv8 ve YOLOv9 mimarileri kullanılarak, 1658 görüntüden oluşan "Ships in Google Earth" veri seti üzerinde gemi tespiti gerçekleştirılmıştır. Modeller; kesinlik, duyarlılık ve ortalama hassasiyet gibi ölçütlerle karşılaştırılmıştır.

Sonuçlara göre, her iki model de başarılı tespitler yapabilmiş, ancak YOLOv9 modeli başlangıçta daha hızlı yakınsama göstererek genel tespit performansında üstünlük sağlamıştır.

Anahtar kelimeler: Derin öğrenme, evrişimsel sinir ağı, gemi tespiti, YOLOv8, YOLOv9.

• • •

# GİRİŞ

Gemi tespiti ve sınıflandırması, deniz gözetimi, balıkçılık yönetimi, göçmen izleme ve askeri operasyonlar gibi alanlarda kritik bir rol oynamaktadır. Geleneksel yöntemler zaman kaybı, hata ihtimali ve yüksek maliyet gibi sorunlara yol açarken, bilgisayarlı görme ve makine öğrenmesi teknikleri bu süreci daha verimli hale getirmektedir.

Uzaktan algılama teknolojileri, geniş kapsama alanı ve düşük maliyet avantajlarıyla gemi izleme çalışmalarında yaygın olarak kullanılmaktadır. Ancak, karmaşık deniz ortamları, nesne ölçek farklılıklarını ve dengesiz veri dağılımı gibi zorluklar, gemi tespitini diğer nesne tespiti çalışmalarının gerisinde bırakmıştır.

Bu noktada, YOLO tabanlı nesne tespiti modelleri, hız ve doğruluk açısından başarılı sonuçlar sunarak öne çıkmaktadır. YOLOv8 ve YOLOv9, özellikle uzaktan algılama görüntülerinde gemi tespiti ve sınıflandırmasını optimize etmek için kullanılmaktadır. Çalışmanın ilerleyen bölümlerinde kullanılan yöntemler, deneyel sonuçlar ve değerlendirmeler sunulacaktır.



# MATERİYAL VE YÖNTEM

...

## YOLO ALGORİTMASI

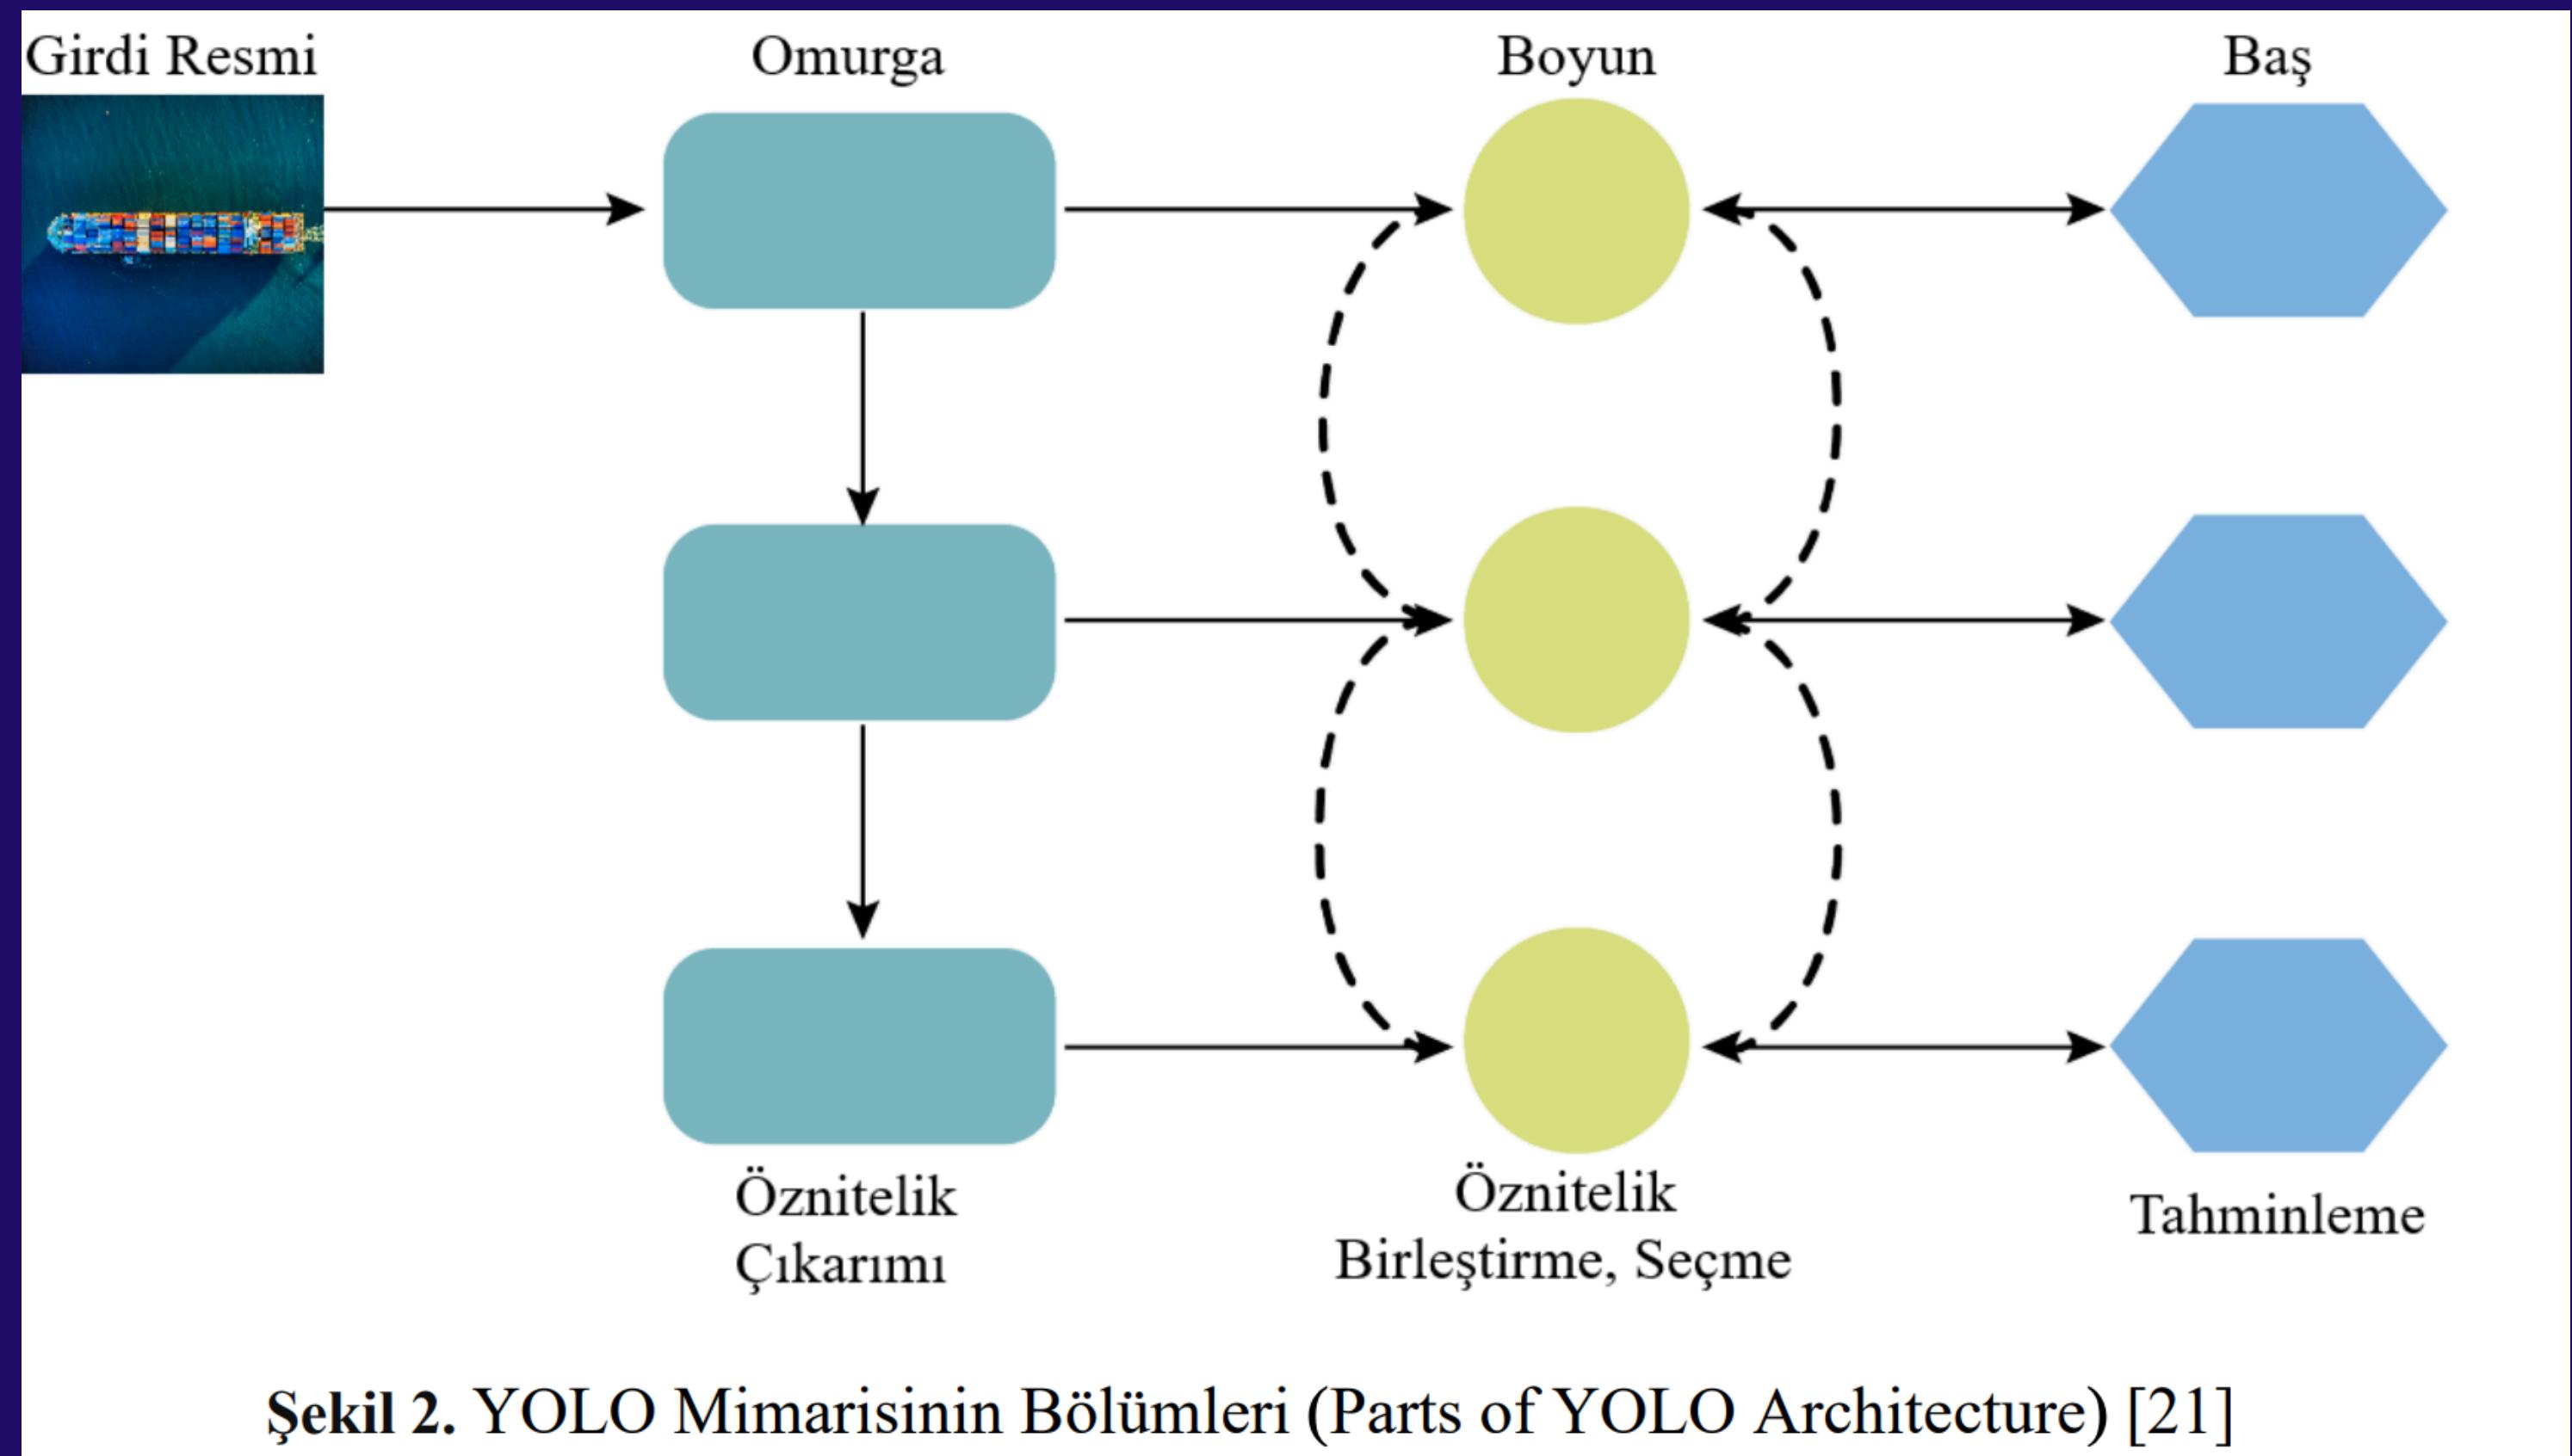
YOLO (You Only Look Once), nesne tespiti için birleşik bir model olup, 2015 yılında Joseph Redmon ve ekibi tarafından geliştirilmiştir. Model, nesne algılama görevini tek bir regresyon problemi olarak ele alarak hesaplama karmaşıklığını azaltır. YOLO mimarisi üç ana bileşenden oluşur:

1. Omurga (Backbone) – Görüntüdeki öznitelikleri çıkarır.
2. Boyun (Neck) – Öznitelikleri birleştirir ve seçer.
3. Baş (Head) – Son tahminleri yapar.

YOLO'nun zaman içindeki gelişimi:

- YOLOv2 (2016): Batch normalization ve Darknet-19 ile daha hızlı ve doğru hale getirildi.
- YOLOv3 (2018): Darknet-53 ile çoklu ölçekli tespit yapabilen gelişmiş bir model sunuldu.
- YOLOv4 (2020): CSPDarknet53, mozaik veri artırma ve CIOU kaybı gibi yenilikler eklenerek doğruluk ve hız artırıldı.
- YOLOv5 (2020): Ultralytics tarafından geliştirildi, PyTorch tabanlı ve hafif bir model olarak dikkat çekti.
- YOLOv6 (2022): YOLOv5'e alternatif olarak PyTorch tabanlı optimize edildi.
- YOLOv7 (2022): Gerçek zamanlı uygulamalara uygun, hız ve doğruluk açısından optimize edilmiş bir model olarak geliştirildi.
- YOLOv8 (2023): Daha iyi kullanım kolaylığı, hız ve doğruluk sunan geliştirilmiş bir versiyon olarak tanıtıldı.
- YOLOv9 (2024): Derin sinir ağı tabanlı yeni nesil nesne algılama algoritması olarak piyasaya sürüldü.

Her yeni sürümle birlikte modelin hız, doğruluk ve kullanım kolaylığı açısından iyileştirildiği görülmektedir.



Şekil 2. YOLO Mimarisinin Bölümleri (Parts of YOLO Architecture) [21]

## YOLOV8 ALGORİTMASI

Ultralytics, Ocak 2023'te tanıtılan YOLOv8 [28], kullanıcılara kapsamlı bir dizi geliştirme ve çok yönlü yetenekler sunarak YOLO serisinde önemli bir gelişme göstermiştir [30]. Mimari, kayıp fonksiyonları ve segmentasyon yeteneklerindeki ilerlemeleriyle YOLOv8, çok çeşitli uygulamalar için güçlü bir araç olarak öne çıkmaktadır [20]. YOLOv8 tarafından önerilen C2f (Cross Stage Partial) modülü, derin öğrenme ağları içindeki gradyan akışını önemli ölçüde iyileştirerek, modelin öğrenme yeteneğini artırmakta ve dolayısıyla daha hızlı bir NMS (Non-Maximum Suppression) sürecine zemin hazırlamaktadır. Bu modül, katmanlar arası geçişlerdeki bilgi kaybını minimize ederken, katmanların iş birliğini güçlendirir ve öğrenim sürecinde daha verimli bir gradyan akışı sağlar. Gradyan akışının optimize edilmesi, modelin daha kısa sürede daha yüksek performans göstermesine olanak tanır, çünkü bu durum ağırlıkların güncellenmesi sırasında daha etkili bir geri yayılım sağlar. Böylece, C2f modülü, tespit süreçlerinde zaman tasarrufu sağlarken aynı zamanda algoritmanın genel verimliliğini artırmaktadır [31].

## YOLOv9 ALGORİTMASI

Omurga ağının birincil işlevi, giriş görüntüsünden özellikler çıkarmaktır. Bu, özellik haritasını iki ayrı bölüme ayıran omurga olarak CSPDarknet53 kullanılarak elde edilir. Bir bölüm derin evrişimsel katmanlardan geçerken, diğer hafif evrişimsel katmanlardan geçer ve daha sonra bu iki bölüm özellik gösterimini geliştirmek için yeniden birleştirilir. Gradyan kaybolması sorununu azaltmak için artık bir yapı benimsenir. Özellik birleştirme ağı, özellik birleştirmeyi başarmak için Mekansal Piramit Havuzlama (SPP) modülleri ve Yol Toplama Ağı (PAN) modülleri kullanarak farklı ölçeklerdeki özellik haritalarını entegre etmekte görevlendirilmektedir. Bununla birlikte, YOLOv9 modeli, önceki nesil YOLO modellerinden birçok kavramı bünyesinde barındırmaktadır. Örneğin, YOLOv5'ten elde edilen CSP Bloğu, YOLOv6'dan alınan RepVGGBlock ve YOLOv7'den entegre edilen ELAN bloğu, YOLOv9'un RepNCSPELAN4 modülünde bir araya getirilmiştir. Bu entegre yapı, modelin öğrenme kapasitesini artırarak daha karmaşık nesne tespiti görevlerinde daha yüksek doğruluk oranları elde edilmesini sağlamaktadır [32].

## VERİ SETİ (DATA SET)

Bu çalışmada, "Ships in Google Earth" veri seti kullanılmıştır. Veri seti, 1658 uydu görüntüsünden oluşmakta olup, farklı hava koşulları, ışık seviyeleri ve çeşitli gemi türlerini içermektedir.

Veri seti üç bölüme ayrılmıştır:

- Eğitim Seti: %86 (1420 görüntü)
- Doğrulama Seti: %10 (159 görüntü)
- Test Seti: %5 (79 görüntü)

Veri Ön İşleme & Artırma

- Ön İşleme: Görüntüler auto-orient ile düzenlenmiş ve 640x640 piksel olarak yeniden boyutlandırılmıştır.
- Veri Artırma:
  - Yatay çevirme (Horizontal Flip)
  - Saat yönünde ve tersine 90° döndürme
  - YOLOv5 formatına uygun sınırlayıcı kutu (bounding box) etiketi eklenmiştir.

Bu süreçler, modelin eğitim performansını artırmak amacıyla uygulanmıştır.

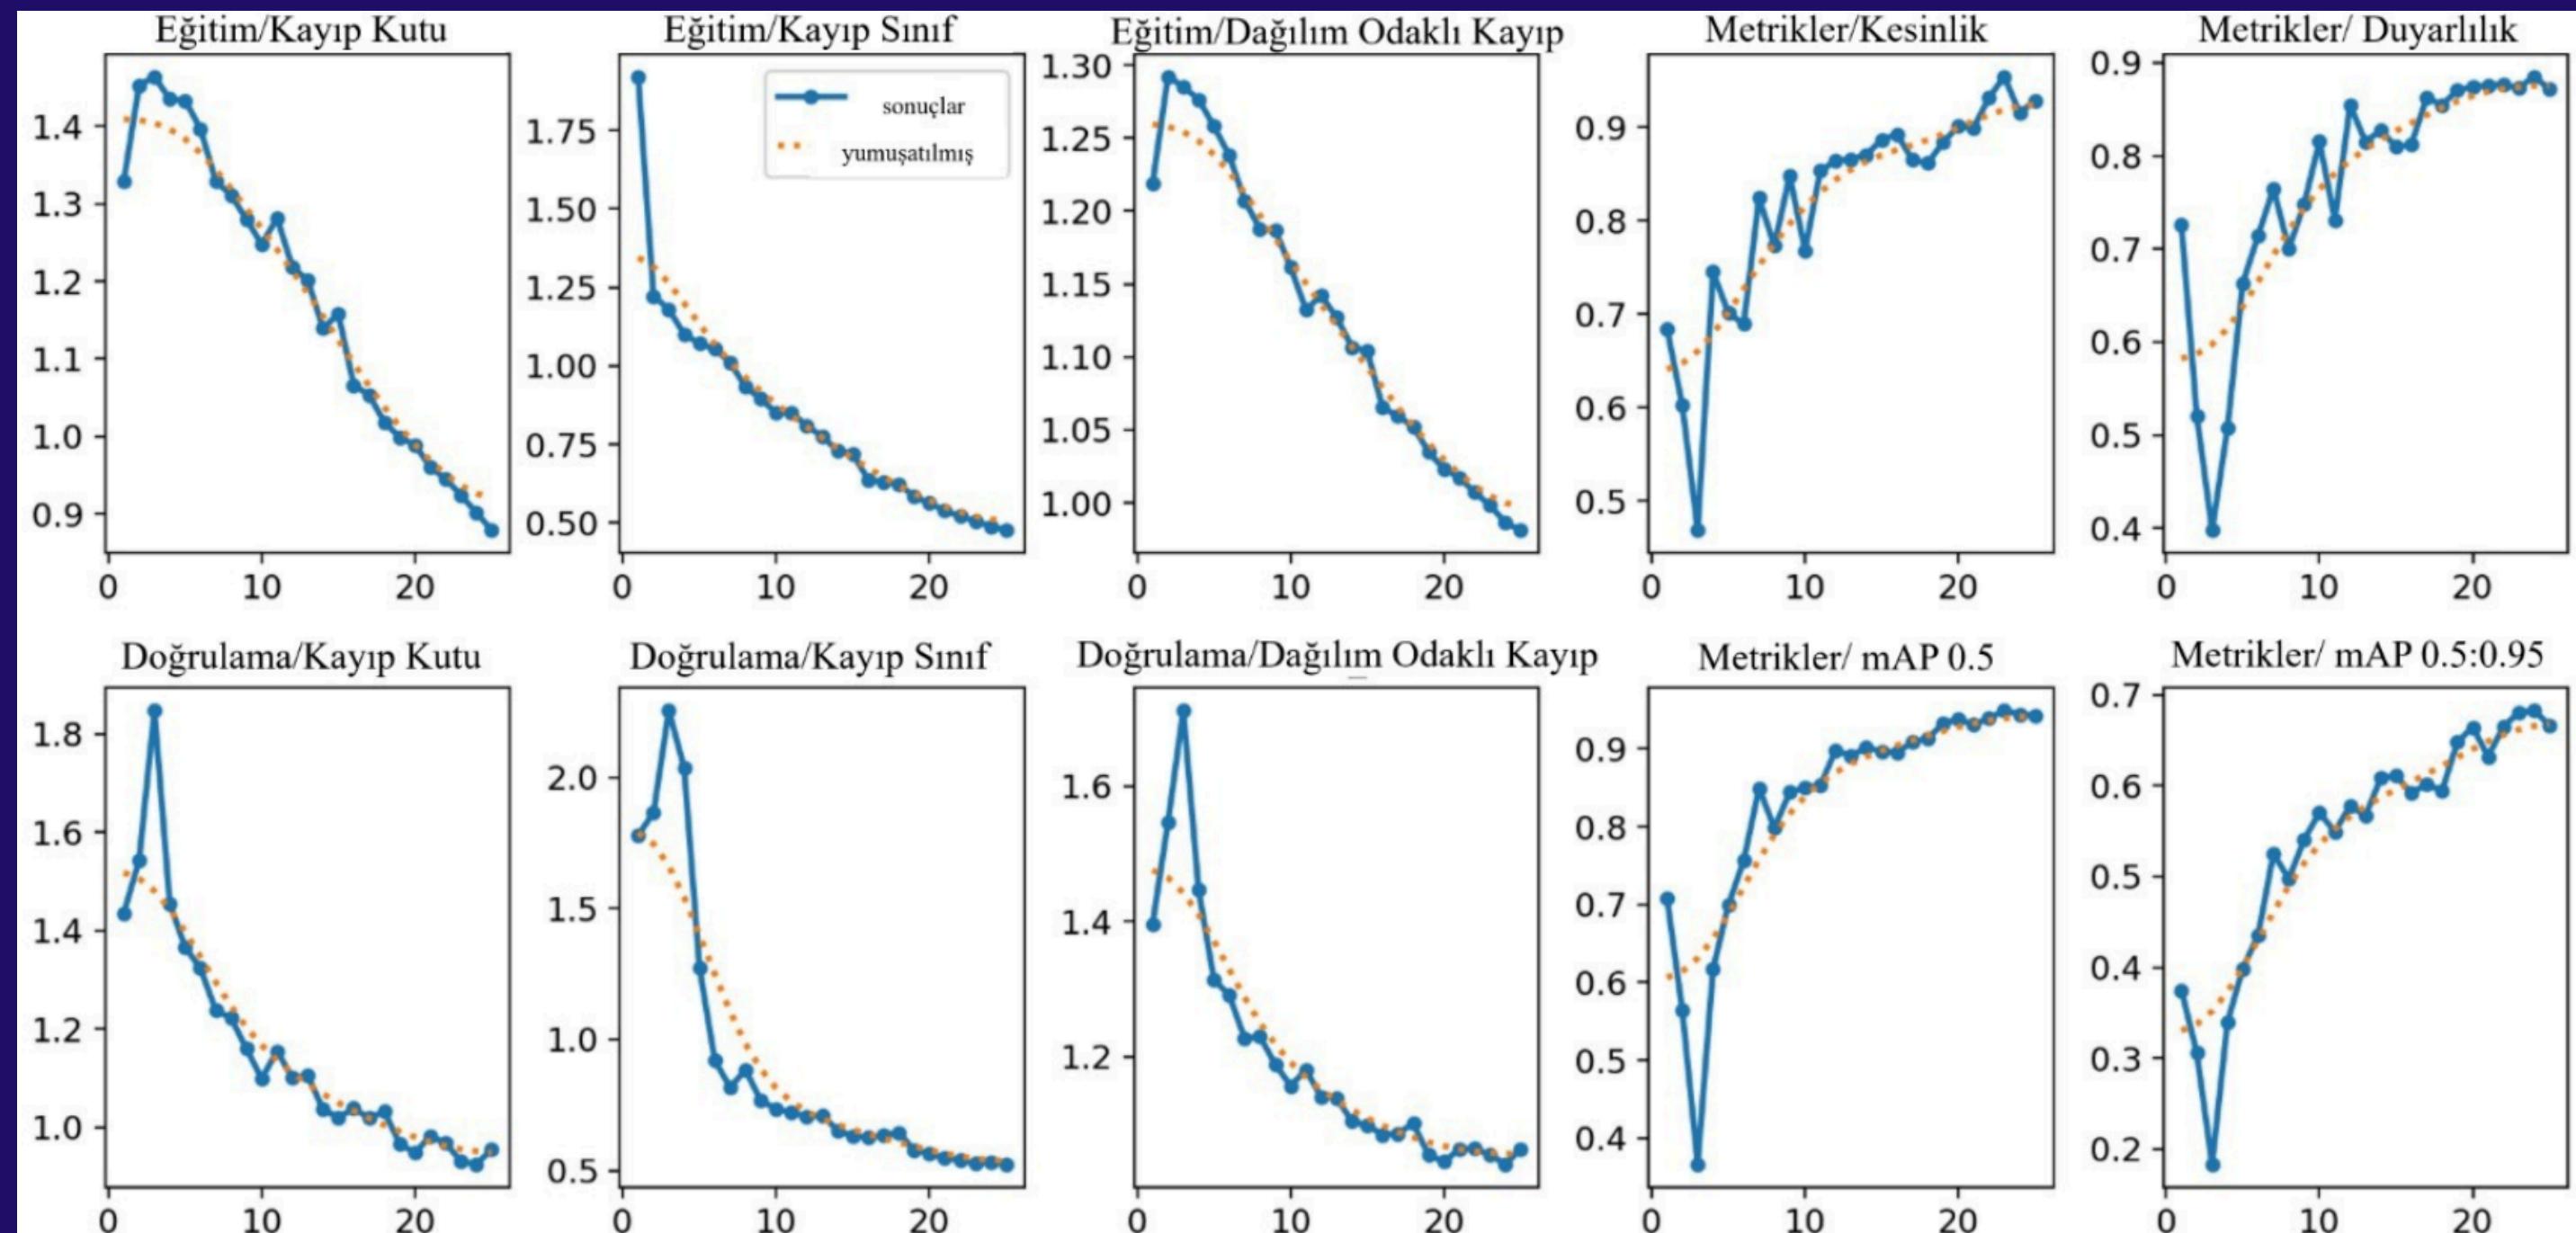


## ARAŞTIRMA BULGULARI

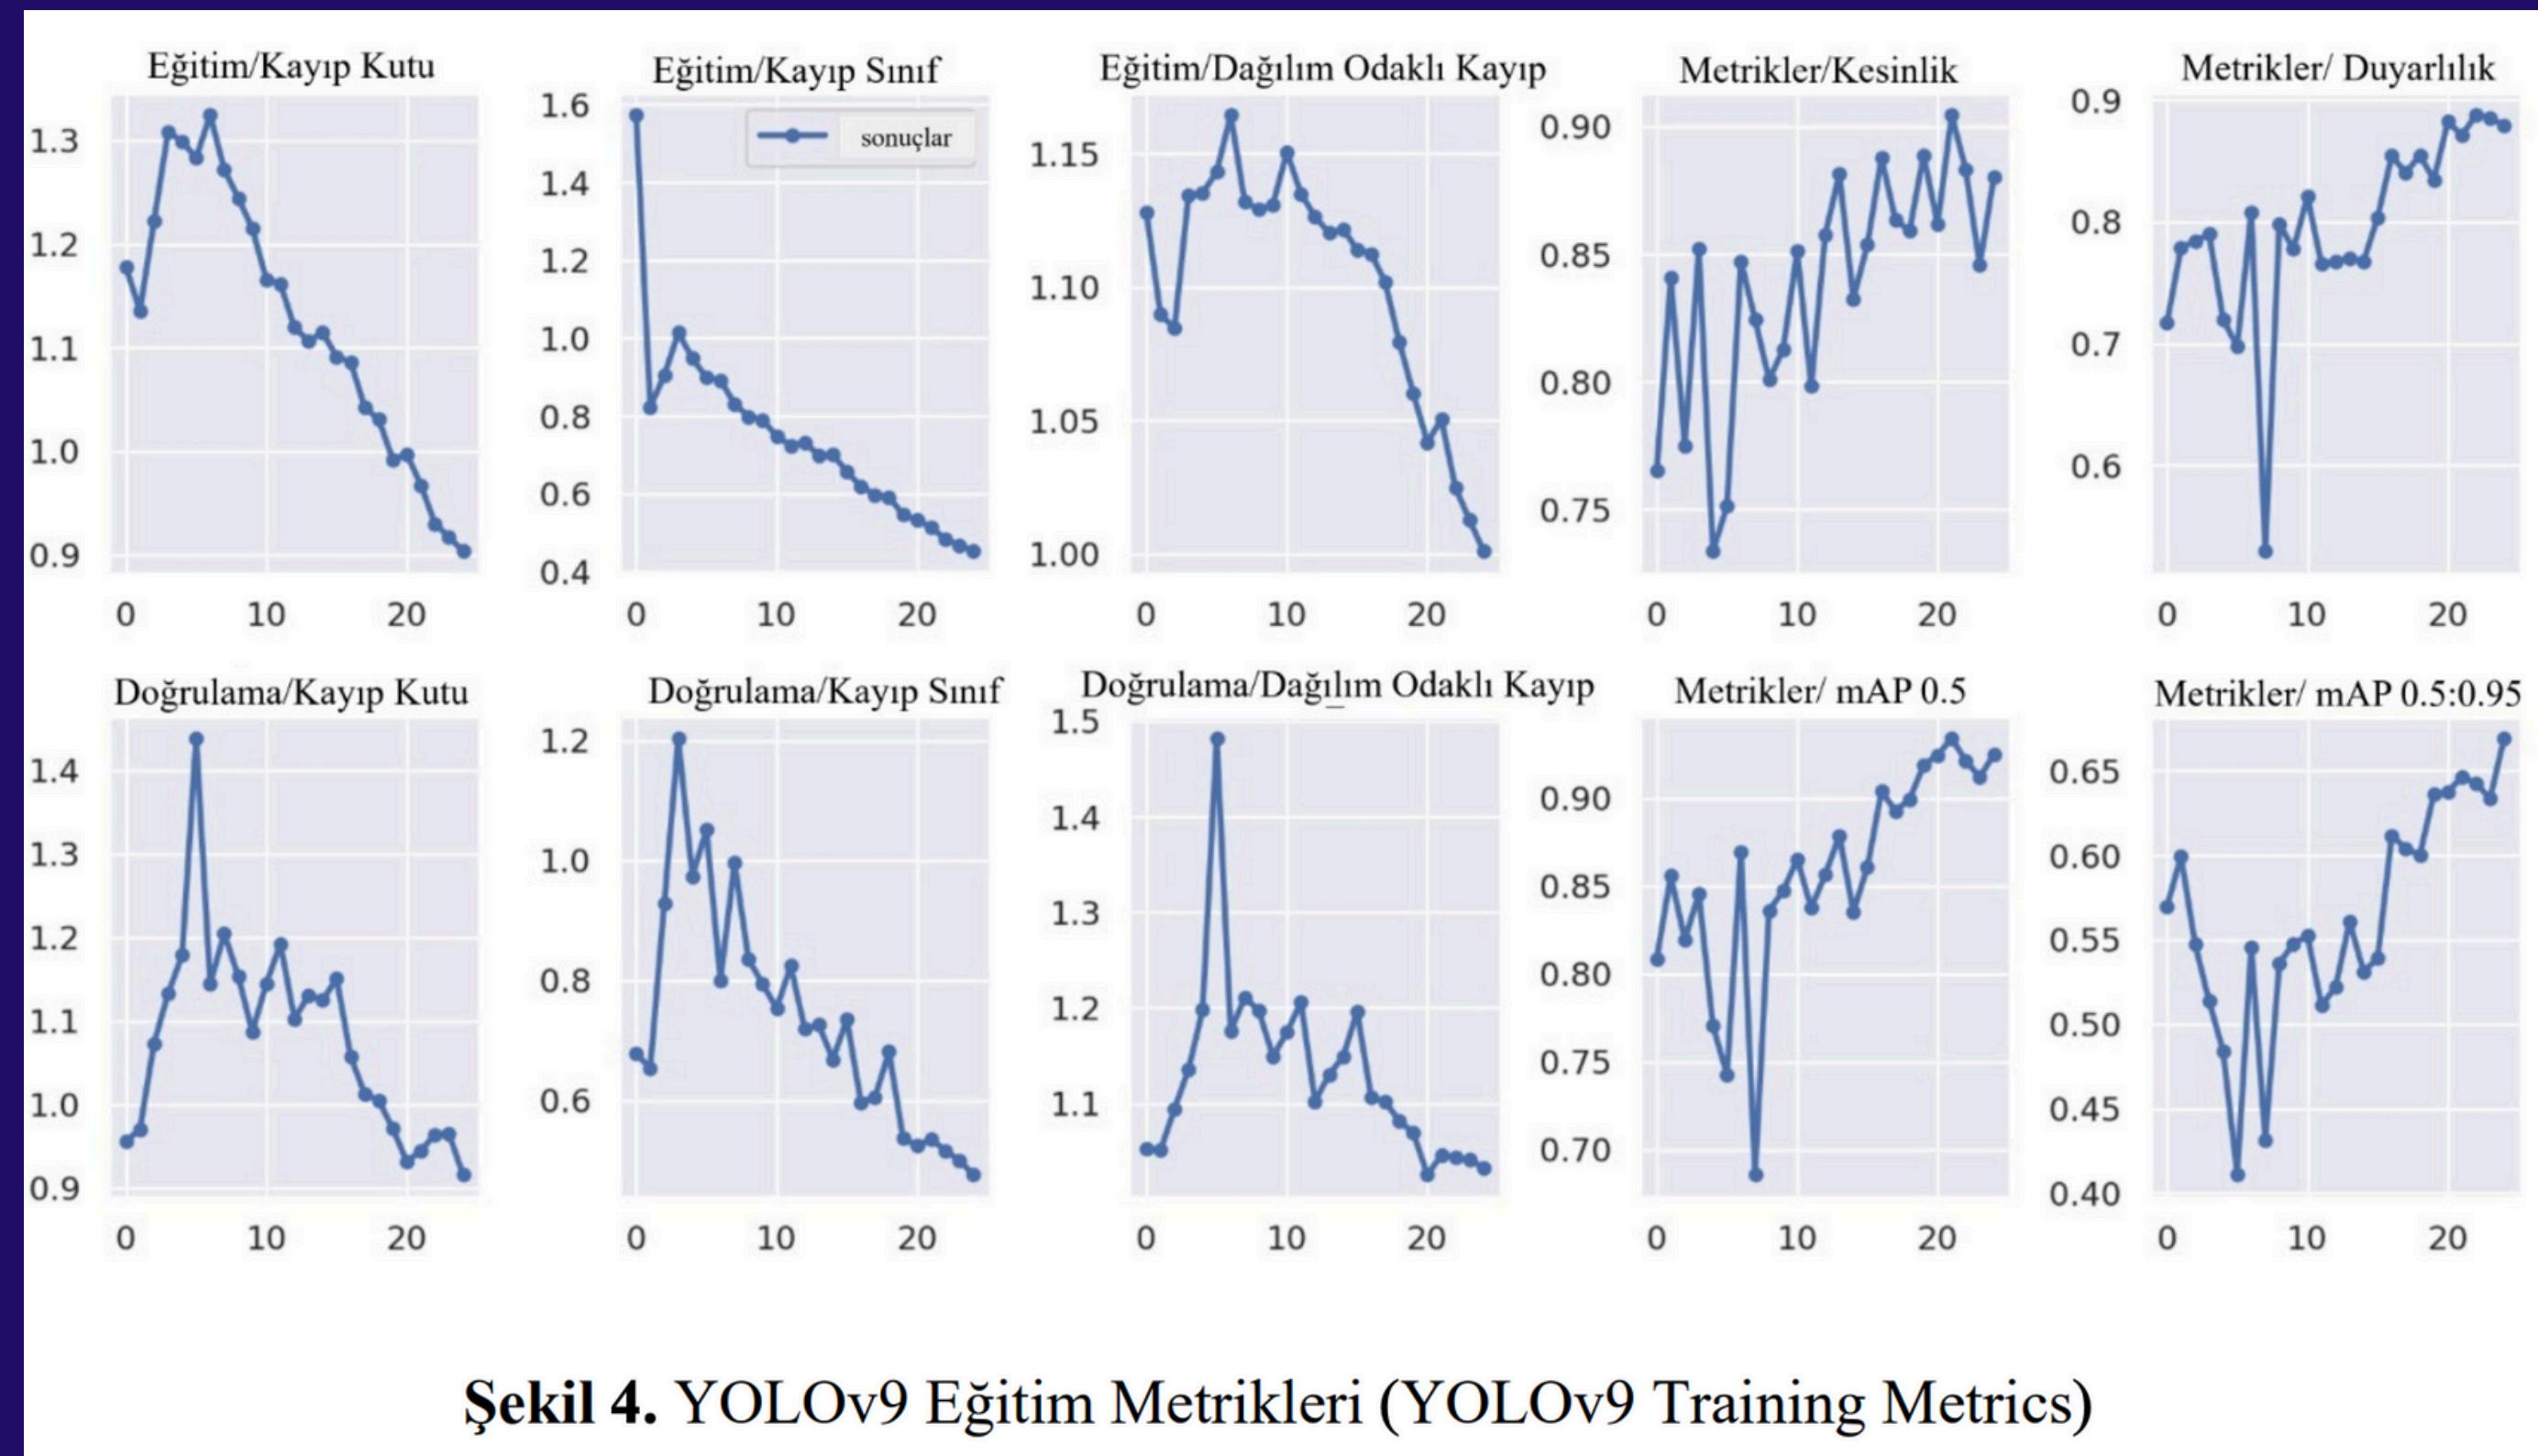
Bu çalışmada, YOLOv8 ve YOLOv9 modelleri üzerinde 25 iterasyon boyunca eğitim yapılmıştır. Eğitimde batch size değeri 16 olarak seçilmiş ve eğitim süreci, başarıda büyük değişiklik gözlemlenmediği için tamamlanmıştır. Eğitim başarısı, kesinlik, duyarlılık ve ortalama hassasiyet (mAP) metriklerine göre değerlendirilmiştir.

Eğitimdeki Değişiklikler:

- **Eğitim Kaybı:** Her iki modelde de eğitim kaybı iterasyon sayısı arttıkça azalmaktadır. YOLOv8'in kayıp eğrileri daha stabil, YOLOv9'un kayipları ise daha hızlı bir düşüş göstermektedir.
- **Doğrulama Kaybı:** Doğrulama kayipları da azalmaktadır, ancak eğitim kayiplarına göre daha fazla dalgalanma göstermektedir. YOLOv9'un doğrulama kayipları sonlara doğru daha düşük seviyede kalmaktadır.
- **Kesinlik ve Duyarlılık:** YOLOv9, eğitimin başlarında YOLOv8'e göre daha yüksek kesinlik ve duyarlılık değerleri elde etmektedir, bu da daha iyi tespit performansını işaret etmektedir.
- **mAP:** YOLOv9, özellikle başlangıç iterasyonlarında YOLOv8'e göre daha yüksek mAP değerlerine ulaşmıştır. Bu, genel tespit performansının daha iyi olduğunu gösterirken, her iki model de yüksek IoU eşiklerinde iyi sonuçlar elde etmiştir. Ancak, YOLOv9 küçük veya gizli nesneleri tespit etmede ufak bir üstünlük sağlamaktadır.



**Şekil 3.** YOLOv8 Eğitim Metrikleri (YOLOv8 Training Metrics)



# SONUÇLAR

İki model, YOLOv8 ve YOLOv9, bu çalışmada gemi tespiti uygulaması için incelenmiştir. Her iki model de YOLO (You Only Look Once) ailesinin üyeleri olup, nesne tespiti ve görüntü segmentasyonu için son teknoloji çözümler sunmaktadır. Bulgularda gözlemlenen sonuçlar doğrultusunda YOLOv9, genel olarak mAP ve duyarlılık açısından YOLOv8'e göre biraz daha iyi performans sergilemektedir. YOLOv9'un gelişmeleri özellikle erken iterasyonlarda belirgin, bu da modelin daha hızlı yakınsadığını ve daha az iterasyon ile eğitildiğinde bile yüksek performans gösterebileceğini işaret etmektedir. Eğer önceliğiniz tespit kalitesi ise, YOLOv9 bu veri seti için daha iyi bir seçim olabilir. Ancak, seçim aynı zamanda çıkışım hızı ve hesaplama verimliliği gibi diğer faktörlere de bağlı olabilir. Her iki modelin de gemi tespiti için etkili çözümler sunduğu görülmüştür. Ancak, YOLOv9'un performansı ve verimliliği, onu gemi tespiti uygulaması için özellikle cazip bir seçenek haline getirirken, YOLOv8 daha geniş bir uygulama yelpazesi sunmaktadır. Bu nedenle, seçim, belirli bir uygulamanın gereksinimlerine ve mevcut kaynaklara bağlı olacaktır.





# KAYNAKÇA

Erkin ÖÇER, N., Teknik Üniversitesi, E., & ve Uzay Bilimleri Enstitüsü, Y. (n.d.). GSI Journals Serie C: Advancements in Information Sciences and Technologies (GSI Dergileri Seri C: Bilgi Bilimleri ve Teknolijilerindeki Gelişmeler) Mask R-CNN İle Uydu Görüntülerinde Gemi Tespiti Ship Detection in Satellite Images with Mask R-CNN.

<https://dergipark.org.tr/tr/pub/aiст>

ŞENOL, H. İ. (2023). Gelişmiş Deniz Gözlemi: SAR Tabanlı Gemi Tespiti için CNN Algoritmalarının Kullanımı. Turkey Lidar Journal. <https://doi.org/10.51946/melid.1267997>

Tekindemir, B., & Şenel, F. A. (2024). GEMİ TESPİTİ UYGULAMASINDA YOLOV8 VE YOLOV9 ALGORİTMALARININ PERFORMANS DEĞERLENDİRMESİ. Uluslararası Sürdürülebilir Mühendislik ve Teknoloji Dergisi, 8(2), 192–199. <https://doi.org/10.62301/usmt.1577868>